

TRABAJO FIN DE MÁSTER

(Máster Universitario en Ingeniería Industrial)

Título Desarrollo de un sistema basado en inteligencia artificial para la detección de vegetación de riesgo en torres eléctricas con fines de prevención de incendios.

Realizado por Javier Martínez Calonge

Dirigido por Dr. Marco Antonio Pérez Martínez

Barcelona, junio de 2025

DECLARACIÓN DE AUTORÍA Y ORIGINALIDAD

D./Dña. Javier Martínez Calonge con DNI 39941838S estudiante del Programa Académico Máster Universitario en Ingeniería Industrial de IQS School of Engineering.

DECLARO

1. Que soy autor/a del Trabajo que presento para su exposición y defensa titulado:

Desarrollo de un sistema basado en inteligencia artificial para la detección de vegetación de riesgo en torres eléctricas con fines de prevención de incendios.

2. Que dicho trabajo es original, no ha sido plagiado ni presentado previamente, y he contribuido directamente al contenido intelectual y a la génesis y análisis de los datos que certifico que son reales y no han sido falsificados.

3. Que las fuentes utilizadas para su realización y aportes intelectuales de otros autores han sido referenciadas en el mismo y no se atenta contra derechos de terceros.

En caso de detectarse fraude, plagio o falsificación asumo las consecuencias y sanciones que se deriven de acuerdo con la normativa vigente de IQS y de la Universidad Ramon Llull.

Y para que así conste firmo el presente documento en

Barcelona, 17 de junio de 2025

Firma

Agradecimientos

Al Dr. Marco Antonio por su dedicación, paciencia y confianza depositada en mí para la realización de este trabajo.

A mi familia, que siempre ha estado conmigo en todos los momentos de mi vida y que me han animado para seguir adelante.

A todos los amigos de la universidad, en especialmente a nuestro grupo *AvalonParado* por el día a día, manteniendo la ilusión y los buenos momentos en el transcurso del Grado y del Máster.

A mí mismo.

Resumen

Este trabajo tiene como objetivo evaluar la viabilidad del uso de imágenes aéreas y satelitales para la prevención de incendios y la protección de infraestructuras eléctricas críticas debido a la vegetación alta en zonas cercanas a las redes de transporte. Consecuentemente, se han identificado los requisitos fundamentales para la detección de vegetación y otros elementos presentes en las imágenes, utilizando algoritmos de aprendizaje profundo, específicamente la segmentación semántica de píxeles. Como primer paso esencial y crítico, se ha creado un conjunto de datos (dataset) compuesto por imágenes de diversas fuentes, tanto aéreas como satelitales, las cuales han sido preprocesadas y etiquetadas manualmente para permitir el entrenamiento de los modelos de clasificación empleados.

Se han implementado y evaluado diferentes modelos de segmentación semántica ampliamente utilizados en la clasificación de píxeles, programados íntegramente en Python. Estos modelos, UNet, DeepLabV3+ y FCN, con aplicaciones en campos que abarcan desde la investigación científica y la teledetección hasta el uso avanzado militar, han demostrado su eficacia en la clasificación de imágenes. Tras diversos entrenamientos y modelos, se han obtenido precisiones globales superiores al 70% en la detección de las clases principales (Vegetación e Infraestructura). No obstante, la disponibilidad, calidad y precisión del etiquetado del conjunto de imágenes ha sido uno de los factores clave que condicionan los resultados, además de la carga de trabajo implicada. Además, se ha evidenciado la necesidad de contar con un conjunto de imágenes de alta resolución específicamente en las zonas delimitadas para analizar, algo que no se tenía al inicio del trabajo.

Los resultados obtenidos confirman que la metodología empleada para el procesamiento de los datos e imágenes permite la detección de zonas con alta vegetación en las áreas analizadas. Se presentan recomendaciones y directrices para fundamentar las bases para escalar el proyecto a un entorno de producción, gracias una mejor optimización, mejora de los recursos disponibles para el etiquetado, entrenamiento, modelado y validación de los modelos, así como la disponibilidad de equipos computacionales de mayor capacidad y un equipo humano experto en el análisis de los datos e imágenes.

Palabras clave: Visión artificial, imágenes satelitales, clasificación de píxeles, segmentación semántica, redes neuronales convolucionales, U-net, teledetección, drones.

Resum

Aquest treball té com a objectiu avaluar la viabilitat de l'ús d'imatges aèries i satel·litals per a la prevenció d'incendis i la protecció d'infraestructures elèctriques crítiques a causa de la vegetació alta en zones properes a les xarxes de transport. Conseqüentment, s'han identificat els requisits fonamentals per a la detecció de vegetació i altres elements presents en les imatges, utilitzant algoritmes d'aprenentatge profund, específicament la segmentació semàntica de píxels. Com a primer pas essencial i crític, s'ha creat un conjunt de dades (dataset) format per imatges de diverses fonts, tant aèries com per satèl·lit, que han estat preprocesades i etiquetades manualment per permetre l'entrenament dels models de classificació emprats.

S'han implementat i avaluat diferents models de segmentació semàntica àmpliament utilitzats en la classificació de píxels, programats íntegrament amb Python. Aquests models; UNet, DeepLabV3+ y FCN; amb aplicacions en camps que abasten des de la investigació científica i la teledetecció fins a l'ús avançat militar, han demostrat la seva eficàcia en la classificació d'imatges. Després de diversos entrenaments i models, s'han obtingut rendiments globals superiors al 70% en la detecció de les classes crítiques (Vegetació Alta i Infraestructura). No obstant això, la disponibilitat, qualitat i precisió de l'etiquetatge del conjunt d'imatges ha estat un dels factors claus que han condicionat els resultats, a més de la càrrega de treball implicada. A més, s'ha evidenciat la necessitat de comptar amb un conjunt d'imatges d'alta resolució específicament a les zones delimitades per analitzar, fet que no es disposava al principi del treball.

Els resultats obtinguts confirmen que la metodologia emprada per al processament de les dades i imatges permet la detecció de zones amb alta vegetació a les àrees analitzades. Es presenten recomanacions i directrius per fonamentar les bases per escalar el projecte a un entorn de producció gràcies a una millor optimització, millora dels recursos disponibles per a l'etiquetatge, entrenament, modelatge i validació dels models, així com la disponibilitat d'equips computacionals de major capacitat i un equip humà expert en l'anàlisi de les dades i imatges.

Paraules clau: Visió computacional, imatges per satèl·lit, classificació de píxels, segmentació semàntica, xarxes neuronals de convolució, U-Net, teledetecció, vehicle aeri no tripulat.

Abstract

This work aims to assess the feasibility of using aerial and satellite imagery for wildfire prevention and the protection of critical electrical infrastructure due to high vegetation in areas near transport networks. Consequently, the fundamental requirements for detecting vegetation and other elements present in the images have been identified, using deep learning algorithms, specifically semantic pixel segmentation. As an essential and critical first step, a dataset composed of images from various sources, both aerial and satellite, has been created. These images have been preprocessed and manually labeled to enable the training of the classification models used.

Different widely used semantic segmentation models for pixel classification have been implemented and evaluated, all programmed entirely in Python. These models; UNet, DeepLabV3+ and FCNs; applied in fields ranging from scientific research and remote sensing to advanced military use, have demonstrated their effectiveness in image classification. After multiple training sessions and models, overall global performance above 70% has been achieved in the main classes' detection (Vegetation and Infrastructure). However, the availability, quality, and accuracy of the dataset labeling have been key factors affecting the results, in addition to the workload involved. Furthermore, the need for a high-resolution image set specifically covering the designated areas for analysis has been highlighted, which was not available at the beginning of the study.

The results confirm that the methodology used for data and image processing allows for the detection of areas with dense vegetation in the analyzed regions. Recommendations and guidelines are presented to establish the foundations for scaling the project to create a production environment by achieving better optimization, improving the resources available for labeling, training, modeling, and validation of the models, as well as to enhance computational capacity and the involvement of an expert team in data and image analysis.

Key words: Computer Vision, Satellite imagery, Pixel Classification, Semantic Segmentation, Convolutional Neural Networks, U-Net, Remote Sensing, Drones.

Índice

- Agradecimientos I
- Resumen II
- Resum..... III
- Abstract..... IV
- Listado de Figuras VII
- 1. Introducción 1
 - 1.1 Motivación..... 2
 - 1.2 Objetivo..... 3
 - 1.3 Antecedentes..... 4
 - 1.4. Normativa aplicable 4
 - 1.5 Cronograma..... 5
 - 1.6 Estructura del documento..... 7
- 2. Fundamento teórico..... 8
 - 2.1 Conceptos básicos sobre Inteligencia Artificial 8
 - 2.2 Visión Artificial o Computacional: Clasificación de imágenes 10
 - 2.2.1 Redes Completamente Convolucionales 14
 - 2.2.2 Arquitectura UNet 17
 - 2.2.3 Arquitectura DeepLabV3 20
 - 2.2.4 Métricas del rendimiento de la segmentación semántica utilizadas 21
 - 2.3. Sistema de Información Geoespacial (SIG) 22
 - 2.3.1 Plataformas de teledetección geoespacial y obtención de imágenes..... 24
 - 2.3.2 Librerías de código Python para la visión artificial y SIG 28
 - 2.3.3 Desafíos técnicos presentes 30
 - 2.4 Justificación de la solución adoptada 30
- 3. Metodología aplicada..... 32
 - 3.1 Creación del dataset..... 32
 - 3.1.1 Imágenes de Dron – Parcela 270 El Puntarró..... 33

3.1.2 Imágenes aéreas PNOA.....	34
3.1.3 Imágenes Satelitales	35
3.2 Máscaras de validación con <i>ImageJ-LabKit</i>	39
3.3 Entorno de la aplicación	45
3.4 Preparación de los datos de aprendizaje	48
4. Resultados	52
4.1 Redes Neuronales Convolucionales Completamente Conectadas	53
4.1.1 Estructura FCN con red base MobileNetV2_Javi	53
4.1.2 Prueba de la arquitectura modelo FCN_ResNet50_Javi	63
4.1.3 Arquitectura modelo UNet_Javi	65
4.1.4 Arquitectura modelo DeepLabV3_Javi	77
4.2 Entorno de aplicación, escalabilidad y mejoras	80
4.2.1 Detección de Vegetación e Infraestructura	80
4.2.2 Otras aplicaciones práctica y escalabilidad: Mapeado de catástrofes, fenómenos meteorológicos y eventos temporales:	86
5. Valoración económica e impacto medioambiental	89
5.1. Costes.....	89
5.2. Impacto Medioambiental	90
5.2.1 Cálculo del impacto	91
6. Conclusiones	92
7. Bibliografía.....	94

Listado de Figuras

Figura 1 Cronograma del TFM	6
Figura 2 Esquema de una neurona humana. Fuente: [9].....	9
Figura 3 Perceptrón de Frank Rosenblatt basado en el cerebro humano de 1958 [12]	10
Figura 4 Ejemplo de detección de elementos en cámara de tráfico [9]	11
Figura 5 Los diferentes tipos de clasificación. Fuente: cs231n.stanford.edu	12
Figura 6 Amplias soluciones en la medicina gracias a la segmentación semántica [13].....	12
Figura 7 Representación visual de la información presente en los píxeles. Fuente: [9]	13
Figura 8 Mosaico multiespectral de Patras (Grecia) con Landsat. Fuente: Propia y GEE ...	14
Figura 9 Longitudes de ondas de las diferentes bandas del Sentinel-2. Fuente: ESA.....	14
Figura 10 Representación de la diferencia entre FCN y CNN [22]	15
Figura 11: Arquitectura general del MobileNetV2 [29]	16
Figura 12 Arquitectura general de ResNet50	17
Figura 13 Arquitectura Original de la red UNet [37]	18
Figura 14 Arquitectura UNet_Javi aplicada a nuestro dataset	19
Figura 15 Arquitectura original general de una red DeepLabV3+ [43]	20
Figura 16 Simplificación de la arquitectura para DeepLabV3_Javi.....	21
Figura 17 Representación visual de la ciencia de teledetección.....	23
Figura 18 Diferentes tipos de adquisición y captura de teledetección geoespacial.....	24
Figura 19 Dataset WorldView_v2 de 2021 de uso del terreno. Fuente: ESA	24
Figura 20 Catalogo de datasets de Google Earth Engine.....	26
Figura 21 Catálogo de UP42 de resolución Óptica	26
Figura 22 Precios de adquisición de SkySat	27
Figura 23 Adquisición del satélite Airbus Pléiades-Neo	28
Figura 24 Entorno de programación de Python en VSCode	28
Figura 25 Canal de Youtube de Dr. Qiusheng Wu, creador de la librería geemap	29
Figura 26 Imagen de Dron seleccionada para nuestro Dataset. Fuente: Propia.	32
Figura 27 Esquema de la obtención del conjunto de datos	33

Figura 28 Dron DJI Mini 2 para la adquisición de imágenes.....	33
Figura 29 Vista del terreno de pruebas con dron el Puntarró, Gorga. Fuente: Propia	34
Figura 30 Centro de descargas de las imágenes del PNOA Fuente: pnoa.ign.es	34
Figura 31 Imagen aérea del dataset de la vía ferroviaria en Lugo. Fuente: PNOA 2021	35
Figura 32 Comparativa de los satélites de observación de la tierra principales	35
Figura 33 Imagen Satelital Airbus Maxar de la parcela Puntarró. Fuente: QGIS	36
Figura 34 Entorno de trabajo de QGIS.....	37
Figura 35 Plataforma de Google Earth Engine	37
Figura 36 Ejecución de GEE en entorno Python.....	38
Figura 37 Mapa personalizado en Python con los datos de GEE.....	38
Figura 38 ESA Clasificación WorldCoverv1 2021 basado en datos Sentinel-2	40
Figura 39 Dataset de UAE Dubái dron	40
Figura 40 Segmentación con ImageJ LabKit.....	41
Figura 41 Ampliación de la imagen segmentada por LabKit.....	42
Figura 42 Información del etiquetado del conjunto de datos	43
Figura 43 Esquema del proceso de obtención y creación del conjunto de datos	43
Figura 44 Imagen original de dron.....	44
Figura 45 Imagen etiquetada de dron	44
Figura 46 GitHub personal con toda la aplicación de códigos creada	45
Figura 47 Detección de Vegetación Alta en zonas de interés.	46
Figura 48 Imagen superior: Original Sentinel-2 Baix Camp, Inferior: ESA WorldCover_v1	47
Figura 49 Predicción con UNet_50Javi entrenada en el dataset WorldCoverv1	48
Figura 50 Representación de la extracción de los parches por clase.....	49
Figura 51 Conjunto de parches de la imagen original por clase	50
Figura 52 Conjunto de parches de la máscara de validación por clase.....	50
Figura 53 Pipeline de la aplicación desde la adquisición hasta la entrada a los modelos....	51
Figura 54 Parámetros de compilación y aprendizaje de los modelos	52
Figura 55 Foto DJI1, 0.102 MIOU Conjunto de datos 6 imágenes	54

Figura 56: Foto DJI1, 0.386 IoU Conjunto de datos 10 imágenes	54
Figura 57 Foto vertical DJI524, IoU de 0.102 Dataset 6 imágenes	54
Figura 58 Foto vertical DJI524, IoU 0.386 Dataset 10 imágenes	55
Figura 59 Resultado de segmentación de la prueba piloto en imagen satelital.	55
Figura 60 Performance Global de la red MobileNetV2 con el dataset al 75%	56
Figura 61 Resultados del MobileNetV2 con el 75% del dataset	57
Figura 62 IoU del modelo MobileNetV2 con el 75% del dataset	57
Figura 63 Matriz de Confusión del Recall de la red MobileNetV2 al 75% del dataset.	58
Figura 64 Parche de Vegetación Alta en dataset MobileNetV2 75%	58
Figura 65 Parche de Infraestructura de MobileNetV2 75%	59
Figura 66 Ejemplos de clasificados por el modelo FCN-MobileNetv2 75%	59
Figura 67 Performance global de la red MobileNetV2 con el dataset completo	60
Figura 68 Resultados del MobileNetV2 con el dataset completo	60
Figura 69 IoU del modelo MobileNetV2_Javi	61
Figura 70 Matriz de Confusión del MobileNetV2_Javi	61
Figura 71 Conjunto de imágenes segmentadas por el modelo MobileNetV2_Javi.....	62
Figura 72 Rendimientos del modelo ResNet50	63
Figura 73 IoU del modelo ResNet50	63
Figura 74 Aplicación del modelo ResNet50_Javi	64
Figura 75 Arquitectura de UNet_Javi utilizada	65
Figura 76 Rendimiento del modelo UNet_10	66
Figura 77 IoU del modelo UNet10	66
Figura 78 Predicciones con UNet10_Javi	67
Figura 79 Rendimiento del modelo UNet20	68
Figura 80 IoU del modelo UNet_20	68
Figura 81 Resultados del modelo UNet20_Javi	69
Figura 82 Rendimiento del modelo UNet30	70
Figura 83 IoU del modelo UNet30	70

Figura 84 Resultados del modelo UNet30_Javi	71
Figura 85 Rendimiento del modelo UNet50_Javi	72
Figura 86 IoU del modelo UNet50_Javi	72
Figura 87 Matriz de confusión de píxeles en UNet50_Javi	73
Figura 88 Resultado del modelo UNet50_Javi img40	73
Figura 89 Resultado del modelo UNet50_Javi img10	73
Figura 90 Resultados del modelo UNet50_Javi	74
Figura 91 Evolución de la IoU por clases según tamaño de dataset	75
Figura 92 Evolución de la F1Score por clase y global según el tamaño del dataset	75
Figura 93 Evolución del aprendizaje de la red DeepLabV3+_Javi	77
Figura 94 Métricas del modelo DeepLabV3+_Javi	77
Figura 95 IoU del modelo DeepLabV3+_Javi	78
Figura 96 Ejemplos de predicción modelo DeepLabV3_Javi	78
Figura 97 Resultados del modelo DeepLabV3_Javi	79
Figura 98 Más resultados del modelo DeepLabV3_Javi	80
Figura 99 Zona de análisis acotada con las agrupaciones objetivos	81
Figura 100 Segmento de la aplicación de detección para la Vegetación Alta	81
Figura 101 Zona objetivo de umbral de 5000 Píxeles (12 detecciones)	82
Figura 102 Zona objetivo-ampliada con un umbral de 1000 píxeles (27 detecciones)	83
Figura 103 Fichero con la información de detección de las 27 detecciones previas	83
Figura 104 Ejemplo de detección de vegetación en imagen satelital 029	84
Figura 105 Ejemplo de detección de vegetación en imagen satelital 024	84
Figura 106 Representación general del flujo de la aplicación	85
Figura 107 Mapa NDVI con los incendios en el oeste de Turquía. Fuente:[62]	86
Figura 108 Zonas de alta temperatura urbana en Madrid. Fuente: ESA	87
Figura 109 Predicción de nuestro dataset en los eventos de la DANA	88
Figura 110 Imagen satelital previa a la DANA. Fuente Airbus Maxar y Propia	88
Figura 111 Imagen satelital posterior a la DANA. Fuente Airbus Maxar y Propia	88

Figura 112 Imagen satelital n2 previa a la DANA. Fuente Airbus y Propia.....88

Figura 113 Imagen satelital n2 posterior a la DANA. Fuente Airbus y Propia89

Figura 114 Desglose de costes89

1. Introducción

La detección de vegetación es clave en las proximidades de las infraestructuras críticas como líneas y torres eléctricas, vías de transporte y/o instalaciones para la prevención de incendios y daños. Abordar esta problemática es fundamental para garantizar la seguridad operacional y el mantenimiento de un buen servicio continuo. La irrupción de la democratización de la inteligencia artificial y el uso de las herramientas derivadas de los Sistemas de Información Geoespaciales (SIG), ofrecen nuevas y potentes soluciones para afrontar las problemáticas, los desafíos y los costes asociados a la vigilancia y supervisión de estas infraestructuras realizadas presencialmente.

En este marco, el presente Trabajo de Fin de Máster busca la creación de una solución innovadora mediante los métodos del aprendizaje profundo (*Deep Learning*) para la detección automática de vegetación, utilizando los datos de imágenes ráster geoespaciales. Este proyecto forma parte de la iniciativa ISAPREF, desarrollada por COMSA y el Institut Químic de Sarrià (IQS) con colaboración de la Generalitat de Catalunya.

La aplicación se encuentra disponible con el conjunto de programas y códigos en el GitHub personal: github.com/JavierMartinezCalonge

La justificación de este trabajo se representa ofreciendo una solución potencial y escalable para contribuir en la problemática de la monitorización de la vegetación en zonas críticas de especial interés. Colateralmente a esta identificación y detección de las zonas con presencia de vegetación alta, se contribuye a la prevención de incendios deseada, gracias al uso de algoritmos de visión artificial y la información obtenida por los datos geoespaciales. A pesar de los desafíos técnicos que conlleva la adquisición de la información y el modelado de las arquitecturas de la IA, los resultados demostrarán el enorme potencial de las aplicaciones derivadas del *Deep Learning* para poder mitigar el riesgo de incendios y la protección de infraestructuras críticas con eficiencia y aprendizaje automático continuo.

1.1 Motivación

Como Ingeniero Industrial y amante de la tecnología, es prácticamente inherente a mí ser, embriagarme de la información sobre las nuevas tendencias e hitos de la ciencia. Nos encontramos en una presente revolución tecnológica que nos obliga a explorar y a revisar los conceptos que tenemos sobre la tecnología y la situación sociocultural que nos encontramos. Siendo un país del viejo continente, nos adentramos en un sistema y balanza de poder, donde la nueva oleada de inteligencia artificial pretende irrumpir en todos los flujos de trabajo: desde la simplificación de tareas mediante su automatización hasta la optimización de trabajos con la eficiencia y precisión de los algoritmos y máquinas sin la labor manual u operacional humana. Esta inteligencia artificial nos presenta múltiples soluciones, pero, también deja entrever unos retos como la calidad, el sesgo, el conocimiento y el control de la información (y datos), la cual recibe y se expone la población. Es una tecnología que está cambiando el mundo y el significado de la sociedad y los valores culturales, a un ritmo más acelerado que otros cambios y revoluciones humanos vividos. Y a mi parecer, nuestra sociedad occidental, y particularmente la europea la cual me encuentro, no tiene ni idea del nuevo “equilibrio” multipolar al que nos adentramos. Aquellos que tengan el poder de la información y la habilidad técnica de controlar más eficientemente los sistemas de Inteligencia Artificial, serán aquellos que liderarán el entorno geoestratégico en este siglo XXI. Y aquí estamos perdiendo, realizando legislaciones y enredos burocráticos sinsentido, sin ser los creadores ni pioneros de esta tecnología. Mientras los otros miembros globales refinan sus sistemas, preparan el conocimiento avanzado a sus exponentes científicos e ingenieros (incluso a su población) y se consolidan en la punta de la lanza de esta nueva supremacía tecnológica, nosotros debatimos las bondades del tapón de plástico.

Pasados 6 meses trabajando en Modelaje y Simulación para Procter and Gamble, pude discernir y observar cómo los términos de Inteligencia Artificial y el futuro de automatización digital es uno de los temas que muchos están siendo foco de inversión de grandes sumas de capital. Sin embargo, hay un trabajo muy extenso y arduo por delante, empezando por una de las problemáticas que observaremos en este trabajo, la calidad y disponibilidad de la información. Sin entrar en detalles confidenciales, parte de mi trabajo se dedicaba en dar una optimización de las líneas de empaquetado durante el arranque, aportando un modelo continuo en el tiempo sobre el estado de esta. Para ello era necesario, integrar todos los softwares, crear los protocolos necesarios para su funcionamiento (PLCs de las máquinas, línea y ordenador central). La información de estos se encuentra muchas veces de forma aleatoria y confusa, donde centenares de operadores e ingenieros lanzan datos poco estructurados o sin documentación clara en los programas y o archivos. Esto crea al final un caos que alguien tiene que solucionar, pero esto conlleva tiempo y recursos. La inteligencia artificial pretende automatizar todos estos sistemas, y facilitarnos esta automatización y eficiencia, pero pocos se fijan que, para conseguir esta nitidez y calidad del sistema, se

requiere un orden y un arduo trabajo en tener un banco de datos ordenado, estructurado y con la información relevante.

Este trabajo se adentra en uno de los campos de la Inteligencia Artificial, la visión artificial o computacional, pilar fundamental para las nuevas técnicas y progresos en la simulación, modelado, predicción, prevención y prescripción de riesgos y eventos. A priori, puede parecer una disciplina que se dedica a “retocar imágenes” o simplemente códigos básicos que reconocen patrones y figuras sencillas, no obstante, la realidad es que la visión artificial también es uno de los pilares fundamentales de la ciencia y tecnología: desde el estudio neurocientífico y médico, hasta la ventaja tecnológica de la industria armamentística actual (p.e. sistemas de guiados de drones y misiles). Es por ello por lo que es fundamental entender, explorar y estar activamente investigando y creando los nuevos sistemas de inteligencia artificial en este nuevo paradigma tecnológico y geocultural.

1.2 Objetivo

El objetivo de este trabajo es estudiar la viabilidad del uso de la inteligencia artificial (IA) para detectar vegetación mediante sistemas de teledetección, de tipo satélites y aéreos, para prevenir incendios, mitigar daños a infraestructuras críticas de transporte, especialmente carreteras y vías de tren. Para ello, se ha desarrollado un flujo de trabajo o metodología (*pipeline*) que integra desde la obtención de las imágenes, su procesado hasta la implementación de modelos predictivos y su ejecución en un entorno operativo.

El alcance principal de este trabajo se limita en el desarrollo de una metodología o flujo de trabajo (*pipeline*) que permita explorar la viabilidad técnica del objetivo principal. Esto implica: la adquisición de las imágenes ráster, la aplicación de algoritmos para el aprendizaje de un modelo de clasificación de imágenes basados en segmentación semántica dedicada a la detección de vegetación alta y otras clases críticas. La salida de esta aplicación deberá analizar los resultados y rendimientos de los diferentes modelos y/o arquitecturas y, presentar una delimitación de las áreas de interés (áreas de vegetación e infraestructura) para su posterior toma de decisiones.

1.3 Antecedentes

Con el fin de crear la aplicación objetivo se ha explorado diversas metodologías e investigaciones en el ámbito de la teledetección aplicada a la vegetación, así como el uso de herramientas de Inteligencia artificial. Un antecedente directo a este trabajo es la investigación del Dr. Ricard Ladó, el cual utilizó algoritmos de clasificación no supervisados (*Clustering*) y el uso del LiDAR para la detección de vegetación y cálculo de la altura de los elementos respectivamente. Para nuestra aproximación, se requerirá de un mayor volumen de datos y el uso de algoritmos supervisados para obtener una mayor precisión y ofrecer un aprendizaje automático continuo. Con la implementación de algoritmos supervisados como la segmentación semántica, resulta en una mayor calidad e información de las características espaciales de las imágenes ráster y los elementos presentes. Para ello fue necesario la creación de nuestro conjunto de imágenes (dataset), el cual no se tenía en posesión.

1.4. Normativa aplicable

Las normativas aplicables a la realización de este TFM han sido las de adquisición, procesamiento y uso del conjunto de imágenes y de código realizado en los diferentes programas.

Las imágenes y datos obtenidos para este trabajo han sido obtenidos por datasets de carácter públicos. Estos incluyen *Creative Commons*, *Open Data Commons*, *Kaggle* y Google Earth Engine *Catalog*.

Las imágenes captadas por dron han sido obtenidas personalmente en un terreno privado. Se ha seguido los principios básicos éticos fundamentales en el uso de la Inteligencia Artificial, siendo estos como la transparencia, protección de datos, no discriminación y la responsabilidad ciudadana englobadas en la regulación europea (EU) 2024/1689 del 13 de junio 2024 del Parlamento Europeo y el Consejo Europeo. [1]

Toda información, modelos, datos y recursos utilizados han sido de carácter público o con fines de investigación educacional universitaria. Se ha citado todas las fuentes, autores, herramientas y partes implicadas a lo largo de este Trabajo de Fin de Máster, conforme los estándares académicos.

1.5 Cronograma

Este Trabajo de Fin de Máster de Ingeniería Industrial fue inicializado en septiembre de 2023 con la toma del objetivo principal que abre esta disertación.

Las horas implicadas han tenido como referencia los 30 ECTS (1 ECTS = 25 horas), calculándose en total como 725 horas. El tiempo que se observa en la gráfica ha sido el estimado para la realización del trabajo, el cual ha sido superior al estipulado. Esto ha sido debido a las horas dedicadas al aprendizaje de Python y el amplio tiempo dedicado al procesamiento de las imágenes, el cual ha supuesto un esfuerzo individual más importante. Asimismo, el cálculo de los modelos también ha implicado largas sesiones de cálculo, donde el uso de las unidades de computación, en nuestro caso, los dos portátiles personales utilizados (MSI GF36 y MSI Katana 15B13V) han estado exclusivamente dedicados a estos procesos sin poder ser requeridos para otras tareas.

Actividad	2023				2024				2025				Horas (h)				
	Sept.	Oct.	Nov.	Dic.	Enero	Febrero	Marzo	Abril	Mayo	Junio	Julio	Enero		Febrero	Marzo	Abril	Mayo
Definición																	5
Documentación inicial																	15
Introducción a programación Python																	60
Herramientas de Teledetección y GIS																	40
Preparación del conjunto de datos																	150
Código																	160
Computación y Cálculos																	84
Análisis de Resultados																	240
Redacción y revisión de la memoria																	150
TOTAL																	904

Figura 1 Cronograma del TFM

1.6 Estructura del documento

Para la realización de este Trabajo de Final de Máster se ha estructurado en los siguientes capítulos:

Capítulo 1: Introducción. Se presenta el objetivo principal, justificación, alcance, normativa, cronograma y antecedentes del proyecto. Se expresa también la motivación personal de este Trabajo de Fin de Máster en Ingeniería Industrial.

Capítulo 2: Fundamento teórico. Se explora el estado del arte de los elementos principales y campos relacionados con nuestro objetivo, siendo estas la teoría detrás de los modelos y algoritmos utilizados, análisis de las soluciones presentes y la justificación de la solución adoptada.

Capítulo 3: Metodología. Se detalla la metodología en el proceso de obtención, creación y procesado del conjunto de imágenes ráster creado (dataset) para su posterior entrenamiento y validación con las arquitecturas de segmentación semántica.

Capítulo 4: Resultados. Análisis del aprendizaje de los modelos, así como las predicciones realizadas por los algoritmos. Finalmente se presenta la ejecución de la aplicación de los modelos de detección de vegetación junto a las líneas de mejora y escalabilidad.

Capítulo 5: Valoración económica e impacto ambiental. Costes e impacto ambiental.

Capítulo 6: Conclusiones. Conclusiones del trabajo realizado.

Capítulo 7: Bibliografía.

2. Fundamento teórico

2.1 Conceptos básicos sobre Inteligencia Artificial


Para iniciar el trabajo se debe primero analizar cuáles son las herramientas que dan pie al trabajo. Para ello hay que entender que es la inteligencia artificial, la visión artificial, y como estos acaban siendo el pilar de investigación de la detección de vegetación en una imagen aleatoria, sino que estas aplicaciones y soluciones comprenden un amplio abanico de oportunidades y problemáticas, desde la teledetección junto con la medicina, la industria, la agricultura, la geopolítica y la sociedad.

¿Pero que es la inteligencia artificial? Esta es la primera cuestión que se debe plantear o encarar, antes de realizar un trabajo sobre el tema. Hoy en día, parece que únicamente sea un término de *marketing* o un eslogan que, puesto en el título de este Trabajo, hace que las neuronas del córtex frontal reaccionen de manera interesada. Es una respuesta de algo nuevo y “guay”, pero la realidad es que poca gente conoce o quiere investigar el alcance de esta herramienta, más que pedir a *Grok* (asistente de la plataforma Twitter) que confirme si lo que un usuario aleatorio ha dicho en la plataforma es verdad, o pedir una receta de cocina al ChatGPT, la cual cualquier libro, persona o búsqueda en Google puedes obtener. La inteligencia artificial no deja de ser un sistema que quiere (intentar) reflejar la inteligencia humana, aprendiendo como los niños pequeños empiezan reconociendo patrones, formas y texturas, asociando a una respuesta cerebral. Las bases de la IA no dejan de ser árboles de decisión, como la neurona simple presentada por Frank Rosenblatt en 1958 [2]. Pero no sólo se quiere una simple puerta lógica, sino que se pretende que estas neuronas o conjunto de ellas, tengan la capacidad de crear y evaluar con diferentes pesos, las jerarquías dentro de las decisiones y dar una respuesta que ofrezca un beneficio. Pero hay que darse cuenta, que es muy fácil y vende mucho hablar de IAs y demás revoluciones tecnológicas, sin no saber que detrás hay múltiples factores con un trabajo extenso y arduo en perfeccionar no solamente el algoritmo matemático, la eficiencia computacional, el sesgo, la calidad del conjunto de datos y, sobre todo, el control del flujo de información. Esto último es la clave de dónde se encuentra el verdadero poder de la IA. Google, Meta, Amazon, OpenAI, DeepSeek, Alibaba..., son empresas privadas, que, con la ayuda de sus respectivos estados gubernamentales (Estados Unidos, Israel y China principalmente) lideran el control de los modelos y los bancos de datos. Estos entes privados y en algunos casos públicos como China, son los que dominan el modelado del Siglo XXI y el nuevo paradigma tecnológico-industrial. Es importante destacar esto, porque a nivel nacional, se encuentra en un páramo desolado totalmente con poco que aportar más que observar desde el gallinero los avances reales y siendo simples peones. [3], [4]

La IA no deja de ser modelos que, dado un *input* o entrada, están programados para dar X resultado según la información y el aprendizaje expresamente diseñado. Si se entrena con datos “*basura*”, el resultado será “*basura*”. Y esto es muy importante, ya que como se verá en la Memoria Técnica, uno de los principales problemas es la falta de datos precisos o de una alta calidad dando lugar a múltiples errores de precisión, ruido y un posible estancamiento del aprendizaje de los modelos.

Para entender el concepto de aprendizaje automático de la IA, hay que presentar y entender la base: las **redes neuronales**.

La inspiración inicial fue entender cómo funciona la red neuronal biológica, la cual presente en el cerebro humano permite procesar la información que se incorpora a través de los diferentes sentidos. Sin adentrarse demasiado en el campo neurológico, se sabe que las neuronas presentes en el tálamo y la corteza visual procesan la información de las imágenes en un sistema jerárquico de estímulos [5], en diferentes niveles de extracción, diseccionando progresivamente todos los patrones (forma, bordes, ...), características y singularidades gracias a los trabajos de Hubel y Wiesel (Premio Nobel 1981)[6]. Esta forma de jerarquizar y procesar imágenes es el análogo y lo que da el nombre a las **redes neuronales artificiales**, el cual es una simplificación del sistema biológico. [7], [8]



Dendrite: Receives signals from other neurons

Soma: Processes the information

Axon: Transmits the output of this neuron

Synapse: Point of connection to other neurons

Figura 2 Esquema de una neurona humana. Fuente: [9]

La primera red neuronal artificial conceptual fue propuesta por McCulloch y Pitts en 1943, los cuales presentaron los primeros modelos matemáticos que intentaban replicar la neurobiológica como puertas lógicas. Posteriormente en 1958, Frank Rosenblatt presentó el Perceptrón, lo que hoy se considera como el precursor de la inteligencia artificial moderna. Fue el primer modelo práctico, el cual dotaba a la neurona artificial de múltiples pesos o sesgo, capaz de poder aprender a clasificar patrones y emular con mayor precisión a la capacidad humana. No obstante, no es hasta 2012, que las redes neuronales artificiales experimentaron un resurgimiento, gracias al hito conseguido en la competición ImageNet [10]

por la arquitectura AlexNet[11]. Se demostró la capacidad de procesar millones de imágenes con un rendimiento y eficiencia nunca vistos, gracias a un uso de unidades de procesamiento gráfico (GPUs) accesibles ya al público general. Este fue el catalizador que revolucionó el campo de la visión artificial y el desarrollo de las múltiples arquitecturas y modelos que se conocen hoy en día.




Figura 3 Perceptrón de Frank Rosenblatt basado en el cerebro humano de 1958 [12]

2.2 Visión Artificial o Computacional: Clasificación de imágenes

La visión artificial es una de las ramas que, como se ha visto en el apartado anterior, está dentro del conjunto de la inteligencia artificial, cuyo objetivo es dotar a las máquinas de interpretar y procesar imágenes automáticamente, mediante modelos y algoritmos matemáticos. Su propósito incluye desde el reconocimiento de objetos en una imagen estática hasta la comprensión en tiempo real de escenas dinámicas y complejas, como por ejemplo las captadas por un vehículo autónomo. Este campo interdisciplinario trabaja y explora la réplica y automatización de las tareas visuales que los humanos realizamos de forma natural, dando soluciones en múltiples campos como la industria, medicina, robótica y seguridad. Las aplicaciones más interesantes son:

- **Reconocimiento de patrones:** identificación de formas, texturas y estructuras en imágenes.
- **Procesamiento de imágenes:** técnicas para mejorar, transformar y analizar imágenes digitales
- **Matemáticas:** Modelos estadísticos, geometría y álgebra computacional.
- **Automatización de procesos**




Figura 4 Ejemplo de detección de elementos en cámara de tráfico [9]

Los tipos de problemas de la visión computacional se pueden diferenciarse entre:

- **Clasificación de imagen:** Clasificación fundamental donde dada una imagen, se espera que la salida sea una variable discreta, única. Se asume que, en la imagen dada, solo se encuentra el objeto, elemento o etiqueta a clasificar. En el primer ejemplo de la Figura 5, el resultado sería “gato”, ya que es el elemento principal de esta, obviando todo lo demás, ya que no importa dónde este el animal, ni en que posición.
- **Clasificación + Localización.** Mismo procedimiento que con la clasificación de imágenes clásica, solo que se añade un polígono geométrico que engloba el elemento detectado.
- **Detección de objetos:** El algoritmo está entrenado en detectar múltiples elementos dentro de una imagen y localizarlos mediante un límite su posición en la imagen.
- **Segmentación semántica:** Identifica la totalidad de los píxeles de la imagen, clasificándolos según las etiquetas entrenadas en el modelo. Estos algoritmos son los utilizados en este trabajo.
- **Segmentación de instancias:** El siguiente nivel de segmentación semántica, no solo se clasifica para nivel de píxel, todos los presentes, sino que también pretende identificar diferentes objetos o elementos dentro de una misma clase.




Figura 5 Los diferentes tipos de clasificación. Fuente: cs231n.stanford.edu

Uno de los avances más importantes en la visión artificial es el desarrollo y segmentación semántica de imágenes (nivel de píxeles), ya que permiten categorizar y diferenciar los elementos dentro de una imagen con gran precisión. La mejora en la eficiencia de estos sistemas en la interpretación del campo visual ha hecho posible un enriquecimiento en el progreso de mejores aplicaciones más fiable y robustas como las que se han mencionado anteriormente. Y son los campos biomédicos, militares y de teledetección (geoespacial y agrícola), son los que se han beneficiado ampliamente de los avances en estas técnicas de visión computacional como se analizará a lo largo del trabajo. En el caso específico de la biomedicina ha sido clave, y en cierto modo, los algoritmos de segmentación semántica han sido creados y diseñados para la detección de enfermedades gracias al poder de mapeado de toda la imagen de entrada, pudiendo analizar el alcance, localización y evolución de la patología a tratar [13] - [19]. El poder y las ventajas de estos algoritmos en visión artificial han encontrado su amplio uso en los demás campos mencionados.




Figura 6 Amplias soluciones en la medicina gracias a la segmentación semántica [13]

En el caso de este trabajo, la teledetección y/o clasificación de imágenes geoespaciales, no deja de ser tan diferente como por ejemplo clasificar gatos/perros, identificar el numero en una matrícula de un automóvil o localizar un tumor en la piel, sino que profundiza en la información contenida en los vectores de los píxeles y espectrales en los datos ráster captados por las constelaciones de satélites y otras fuentes ópticas. Y aquí entra un factor crítico: **la resolución**. Si se decide por el uso de satélites de menor resolución como Landsat/Sentinel-2 donde no se puede apreciar correctamente las vías o árboles singulares que afectan la zona de estudio. Debido a que los píxeles contienen diversas clases o no se distinguen por la resolución espacial. Por eso toda la información que se dé al modelo debe estar preparada para obtener resultados deseados. Esta información bien etiquetada y diseñada, tendrá los datos vectoriales de los píxeles (Figura 7), los cuales, junto con el conjunto de bordes, texturas, conexiones con otros elementos, iluminación..., que permitirán a los modelos de aprendizaje realizar correctamente la tarea de segmentación.




Figura 7 Representación visual de la información presente en los píxeles. Fuente: [9]




Figura 8 Mosaico multiespectral de Patras (Grecia) con Landsat. Fuente: Propia y GEE




Figura 9 Longitudes de ondas de las diferentes bandas del Sentinel-2. Fuente: ESA

2.2.1 Redes Completamente Convolucionales

Las redes completamente convolucionales son la aplicación de la arquitectura de red neuronal que tiene como característica su objetivo de clasificar cada píxel de la imagen, presentada en 2015 por Long *et al* [20]. La diferencia con las redes neuronales clásicas (CNN), es que la FCN todas las capas son convolucionales y el no uso de capas densas. El porqué de esta eliminación de la capa totalmente conectada o capa densa, es que el resultado no es clasificar la imagen completa (p.ej, esta imagen es un “árbol”; problema de la clasificación de objetos), sino que se quiere analizar qué píxeles son de cada elemento y mantener el tamaño de la imagen, resultando en un mapeo de píxeles (segmentación semántica). Para ello se utiliza las técnicas de *Downsampling* y *Upsampling*, las cuales con el uso de capas convolucionales reducirán o aumentarán la imagen extrayendo las características de alto nivel de la imagen manteniendo la información de resolución espacial

inicial de entrada en la salida. Así el resultado del modelo es un mapa de píxeles el cual ofrece la información de qué píxeles son “árbol” y que clase son los píxeles del entorno: tierra, sotobosque, carretera... [21] -[23]




Figura 10 Representación de la diferencia entre FCN y CNN [22]

A) MobileNetV2

La toma de MobileNetV2 como red base proporciona un modelo más ligero y optimizado para una mayor computacional y una inferencia más rápida, lo que confiere una gran ventaja al usar equipos con recursos más limitados como pueden ser los portátiles en uso. Esta red base de las arquitecturas MobileNet [24], se ha empleado en nuestro conjunto de datos debido a que presenta un diseño eficiente y de un costo computacional bajo en comparación con las otras redes utilizadas en la visión computacional. El uso de estas redes más livianas es óptimo y muy orientativa en conjuntos de datos más medianos para poder extraer resultados. La particularidad distintiva y que ha hecho que la iteración más moderna y actual, MobileNetV2 [25], reside en el uso de bloques residuales invertidos (*Inverted Residuals*) juntamente con convoluciones separables en profundidad (*Depthwise Separable Convolutions*), técnicas que contribuyen significativamente a su eficiencia particular, dado que eliminan gran parte de parámetros y operaciones en el cálculo. Gracias a ello se pueden obtener grandes resultados en diversos campos de estudio como la biomedicina, agricultura y otros. [17], [18], [26] - [28]




Figura 11: Arquitectura general del MobileNetV2 [29]

La arquitectura creada sigue esta forma general de la red, modificada para el tamaño de imágenes y clases a analizar, siendo:

- **Encoder o Codificador (Extracción y *Downsampling*):** El encoder se encarga de procesar la imagen, extrayendo toda la información contenida a medida que disminuye la resolución de la imagen. La red principal usará las capas necesarias hasta la resolución 8x8, proporcionando así, la capacidad de aprender características de la imagen, desde las más simples (bordes y texturas) hasta las más complejas de cada clase (contrastes), crucial en la identificación de las clases principales como los árboles y las infraestructuras. Asimismo, se reduce el tiempo de entrenamiento considerablemente, al optimizar mejor las capas de la arquitectura.
- **Decoder (*Upsampling* y Segmentación):** El decoder se encarga del objetivo de recuperar la información y devolver de vuelta la imagen a la resolución original perdida en el codificador, reconstruyendo la información espacial, generando el mapa de segmentación.

B) ResNet50

Esta arquitectura más compleja está principalmente diseñada en 2015 [30] para la clasificación de objetos, no obstante, gracias a la API de Keras en TensorFlow, se ha creado una red FCN como se ha hecho previamente con MobileNetV2 [31] - [33]. Esta aplicación tiene como característica principal la incorporación de bloques residuales, que pretenden evitar la pérdida o degradación de la información, sumado a las *skip connections* que permiten en las conexiones encoder-decoder (se observará más detalladamente en la arquitectura UNet), la preservación de la información espacial.




Figura 12 Arquitectura general de ResNet50

Para el código se han adaptado con las capas convolucionales necesarias para la extracción de características. Se incorporan de los bloques residuales característicos de esta red juntamente con las conexiones de salto, que conectarán las salidas del encoder con las capas del decoder correspondientes, las cuales pretenden mejorar flujo de la información y la mitigar la desaparición del gradiente. [34]

2.2.2 Arquitectura UNet

Las arquitecturas UNet son la siguiente evolución de las redes neuronales convolucionales de tipo FCN previamente mencionadas, dedicadas y construidas especialmente para la problemática de segmentación semántica en la visión computacional [22]. La primera red UNet fue presentada en 2017 por *Ronneberger et al.* [34], para presentar una solución óptima y precisa en el campo biomédico [13] - [15]. Esta arquitectura presentaba una alta eficacia y un diseño que aprovecha una gran capacidad para extraer características a múltiples niveles de abstracción y resolución espacial, así como excelente localización, generalización y uso de recursos para conjuntos de datos no muy amplios. Fruto de estas prestaciones ha sido el pilar de muchas investigaciones científicas y ganadora de múltiples competiciones en segmentación de imágenes como la competición de Detección de Células y Microscopia Electrónica del ISBI (*International Symposium on Biomedical Imaging*) [35], [36].




Figura 13 Arquitectura Original de la red UNet [37]

Partiendo de la Figura 13, se adaptan y modifican los parámetros de esta arquitectura para el conjunto de imágenes propio a la resolución 128x128 a segmentar, en el caso objetivo es de 7 clases distintas, en vez de una salida binaria (ver Figura 14). Para ello se define el codificador (encoder) y el decodificador (decoder) unidas por las conexiones de salto (*skip connections*), y un cuello de botella que unirá por el centro las dos rutas formando la forma de U clásica:

- El **codificador** presenta 4 bloques descendentes. Cada bloque se inicia con dos capas de convolución 3x3, para extraer las características a diferentes niveles de extracción espacial. El número de neuronas o filtros usado inicialmente es de **64**, el cual irá progresando a 128, 256 y 512 sucesivamente, permitiendo extraer los detalles finos y complejos durante la reducción de la resolución provocada por la siguiente capa de *MaxPooling*. Esta última capa, permite reducir en un factor de 2 la resolución espacial de la imagen (128x128 – 64x64 – 32x32 – 16x16 – 8x8), concentrando la información más relevante extraída de cada bloque.
- El cuello de botella o **bottleneck**, ofrece en la arquitectura UNet la extracción a más alto nivel (dos capas convolucionales de 1024 filtros en parches de resolución 8x8) de nuestras imágenes de entrenamiento, extrayendo las características más abstractas y finas.
- El decodificador o **decoder** tomará a la inversa lo realizado en el encoder, formado también por los 4 bloques ascendentes donde se devolverá la imagen de entrada a

la resolución original y otorgará el mapa de segmentación. Para ello se utilizan las convoluciones transpuestas que permiten doblar la resolución espacial (*upsampling*). Antes de entrar al primer bloque (y al resto de bloques del decodificador), se aprecia la presencia de la concatenación de las **conexiones de salto** desde los respectivos bloques homólogos del *encoder*. Estas conexiones fundamentales en las redes UNet (también presentes en ResNet50), permiten refinar y mejorar el mapeado de la segmentación, así como recuperar detalles finos y espacialmente complejos que se han podido perder durante el *MaxPooling* (*downsampling*) del codificador. Finalmente, la red concluirá con una última capa convolucional 1x1, que permitirá mapear las 7 clases segmentadas durante el aprendizaje.




Figura 14 Arquitectura UNet_Javi aplicada a nuestro dataset

2.2.3 Arquitectura DeepLabV3

En los últimos años se han explorado más soluciones y arquitecturas para la segmentación semántica de imágenes y una de estas ha sido la arquitectura DeepLab [38], [39], basada en las redes FCN previamente vistas y desarrollada por Google. Esta red introduce un nuevo tipo de convoluciones denominadas *ASPP* (*Atrous Spatial Pyramid Pooling*), o convoluciones dilatadas, las cuales mejoran la captura de información de la imagen a diferentes escalas sin alterar la resolución ni los recursos computacionales. Si se observa el benchmarking de resultados de algunos de las competencias más importantes en clasificación de imagen, esta arquitectura y sus variaciones se encuentran en las que obtienen mejores resultados y uso [40], [41], [42].




Figura 15 Arquitectura original general de una red DeepLabV3+ [43]

Para la red DeepLabV3_Javi se empleará esta arquitectura basándose en la arquitectura original y el código de la plataforma Keras [44], donde se adaptará para nuestras imágenes de entrada las clases a analizar. En esta arquitectura se utilizará como red base pre-entrenada MobileNetV2, que permitirá extraer las características principales. La aplicación de los bloques ASPP se aplicarán a las salidas de las capas de alta resolución de la capa 16x16 (detalles complejos) y la de baja resolución 64x64 (detalles espaciales), como se puede observar en la implementación (Figura 16).




Figura 16 Simplificación de la arquitectura para DeepLabV3_Javi

2.2.4 Métricas del rendimiento de la segmentación semántica utilizadas

En el caso objetivo presente hay que tener en cuenta que se centra en el desarrollo de un modelo de segmentación semántica con múltiples clases etiquetadas. Para ello, el análisis posterior y evaluación de los modelos se evalúan con las múltiples métricas estándares que se implementan en el campo de visión computacional y de Machine Learning, siendo estas:

- **Accuracy (Exactitud):** La métrica que indica la cantidad de píxeles clasificados correctamente.

$$Accuracy \text{ (Exactitud)} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision (Precisión):** La proporción de píxeles clasificados como positivos que son realmente positivos.

$$Precision = \frac{TP}{TP + FP}$$

- **Recall:** La proporción de píxeles positivos que fueron correctamente clasificados por el modelo. También conocida como sensibilidad.

$$Recall = \frac{TP}{TP + FN}$$

- **F1 Score:** Media armónica entre la precisión y el *recall*, Métrica importante en las tareas de segmentación debido a su foco en el análisis de las clases desbalanceadas.

$$F1Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{TP}{TP + 1/2(FP + FN)}$$

- **Intersección sobre la unión (IoU):** Métrica de alta importancia en los problemas de segmentación semántica que proporciona la precisión de la superposición entre la predicción del modelo y la máscara verdadera o *ground truth*.

$$IoU = \frac{TP}{TP + FP + FN}$$

En estas ecuaciones. **TP (Verdaderos positivos)** representa los píxeles clasificados como positivos y son correctamente positivos, **TN (Verdaderos Negativos)** píxeles negativos y clasificados como negativos; **FP (Falsos Positivos)** píxeles clasificados positivos, pero son realmente negativos y; **FN (Falsos Negativos)** píxeles clasificados negativos, pero son realmente positivos.

2.3. Sistema de Información Geoespacial (SIG)

La importancia de estas redes neuronales artificiales también tiene su importancia en otros campos científicos y tecnológicos, fuera de computación matemática y medicina. Los avances generados por el aprendizaje profundo y su uso en la visión artificial han potenciado la rama de teledetección enormemente en la segunda década del siglo XXI [45] - [47]. La teledetección es la disciplina científica de adquisición de las propiedades físicas de un área mediante la captura, adquisición, visualización y análisis de todos los elementos presentes en la superficie de la tierra desde la distancia [47]. En el ámbito geoespacial, los sensores captan los datos del espectro electromagnético (ráster y datos vectoriales), y se les realiza el procesamiento adecuado según el objetivo a solventar utilizando las herramientas computacionales de los Sistemas de Información Geográfica (SIG o G/S). La adquisición se puede dar por diferentes tipos de sensores montados en diversas plataformas, las cuales son principalmente satélites (públicos y privados) [49] y aparatos aéreos de todo tipo (aeronaves tripuladas y UAVs).




Figura 17 Representación visual de la ciencia de teledetección

La implementación y expansión de las técnicas de la Inteligencia Artificial en este campo ha potenciado enormemente la capacidad de la disciplina de teledetección, ya que ha permitido automatizar la extracción de la información y crear algoritmos de análisis y procesamiento de las imágenes ráster, los cuales anteriormente presentaban un trabajo arduo y computacionalmente costoso y lento [50], [51]. Gracias a la inclusión de las técnicas del Deep Learning en el GIS, se ha podido dar múltiples soluciones y herramientas para solventar diferentes problemáticas que ocurren en la superficie de la tierra. En ellas se pueden destacar aquellas dedicadas principalmente al uso de la tierra (agricultura, infraestructuras...) [52] - [57], el control medioambiental (prevención y gestión de eventos meteorológicos y/o causados por la acción humana como incendios) [45], [58] - [63], y muchas otras en diferentes disciplinas que se puedan enriquecer de estos datos [46]. Este proyecto está dentro de las soluciones de la teledetección dedicadas a la prevención de incendios y del uso del terreno para detectar masas vegetales. Las investigaciones y trabajos mencionados previamente se nutren de unos conjuntos de datos de imágenes ráster creados o confeccionados, de adquisición pública o de forma privada. Los datasets existentes ampliamente usados, que son de carácter público (*ESAWorldView*, *DeepGlobe*, *Corine*, *Pasca/VOC*...) utilizan satélites con resoluciones espaciales de 10 metros por píxel, los cuales en la mayoría de las aplicaciones es suficientemente precisa. No obstante, para el nivel de extracción que se desea en este trabajo, se requiere una resolución mucho más precisa la cual está disponible en usos de satélites privados o de datasets aéreos. Estos últimos son muy escasos y costosos. Es por ello, que se decidió crear un dataset propio, usando las fuentes geoespaciales necesarias y creando el pipeline necesario para su escalabilidad y aplicación.




Figura 18 Diferentes tipos de adquisición y captura de teledetección geoespacial




Figura 19 Dataset WorldView_v2 de 2021 de uso del terreno. Fuente: ESA

2.3.1 Plataformas de teledetección geoespacial y obtención de imágenes

En el transcurso del trabajo se ha hecho uso de varias plataformas y softwares punteros en la observación de la tierra y en el mundo geoespacial. Se presentan las más influyentes y críticas para el transcurso del proyecto.

A) Google Earth Engine

Google proporciona un amplio abanico de miles de imágenes ráster históricas de la observación de la tierra y geoespacial, gracias a los conjuntos de datos ya almacenados en los servidores de Google. Únicamente se requerirá una cuenta y se preselecciona la opción de uso académico. La opción permite un abanico limitado de uso, limitando la cantidad de datos para el cálculo, y las capacidades de descarga y prioridad en la nube. No obstante,

esta plataforma está en continua mejora e implementación de librerías externas, que permiten el procesamiento de datos.

Públicamente, se pueden obtener datos **muy** limitados alta resolución de 0.5 metros por píxel del Satélite privado PlanetLabs SkySat. No obstante, estos datos son del 2014/2015 y en diferentes ubicaciones predeterminadas y muy acotadas. Una de las infraestructuras que se tiene como objetivo monitorizar, son las vías de ferrocarril. De las zonas con imágenes satelitales de alta resolución, no se tiene presencia de vías de tren para el aprendizaje del modelo, no obstante, se puede utilizar las zonas boscosas, vegetación y construcciones humanas, para extraer píxeles para el entrenamiento. Asimismo, la información de las bandas y la reflectancia de estos objetos dan la información necesaria. Por ejemplo, al utilizar el NDVI en imágenes de alta resolución, se puede determinar vegetación profunda (árboles), los cuales son los más críticos frente las líneas eléctricas. Otra herramienta interesante es la detección de cuerpos de agua y sus variaciones en el tiempo (control de ríos, pantanos y oleaje). Asimismo, se podrían crear series temporales para detectar cambios significativos y realizar las medidas preventivas correspondientes con el fin de evitar que estos cuerpos pueden dañar las instalaciones [64], [65]. La información satelital de menor resolución puede ser clave, ya que su enfoque es en las fluctuaciones de grandes áreas terrestres.

Sin embargo, se requiere un conjunto de datos grande y exhaustivo para poder tener una predicción correcta. Es por ello por lo que, se aboga por el uso de satélites de más alta gamma. Debido a que ni el Sentinel-2, ni el Landsat de carácter público, permiten tener imágenes limpias y precisas, ya que trabajan con resoluciones de 10 metros escalados y 30 metros/píxel respectivamente. Con esta resolución, se hace prácticamente inviable un uso con el nivel de detalle que se requiere para el objetivo principal. No obstante, como se ha comentado, se podrían realizar y programar otra serie de aplicaciones interesantes a explorar en un futuro, como parte de la escalabilidad o propuesta de soluciones a otro tipo de problemática.

Categorías de conjuntos de datos



Figura 20 Catalogo de datasets de Google Earth Engine

B) Plataforma UP42

Una opción muy interesante en la recolección de datos satelitales es la implementación de la plataforma UP42, la cual cuenta con una amplia de datos satelitales y a demanda de diversas agencias públicas y privadas. Des estas últimas se destaca AIRBUS i Beijing3-A, siendo estas la empresa de defensa y aeroespaciales.

Optical — Catalog

[View all optical data](#)

Search for and order archive geospatial imagery from the world's leading data providers.




Figura 21 Catálogo de UP42 de resolución Óptica

No obstante, la plataforma requiere del uso de créditos para comprar las imágenes. El costo varía según el satélite y el área de seleccionada. La plataforma obliga a pedir un mínimo de km², lo que en eleva el costo enormemente. También la plataforma ofrece recolección histórica de satélites, las cuales pueden ser de gran ayuda para el propósito final. Para un uso a escala industrial/empresarial, la plataforma requiere una autenticación y unos permisos como tal. Para el fin de este trabajo académico, se utilizó la versión profesional académica. Aun así, los precios de realizar una orden de captura de imágenes a cualquiera de las constelaciones disponibles de satélites son extremadamente costosas. Sin embargo, a modo de aplicativo a gran escala y en un entorno industrial de negocio, el uso de estas plataformas son extremadamente clave si se desea obtener se quiere quedar en constancia que, siendo rentable y/o explorando empresarialmente un acuerdo se podría conseguir un mejor acuerdo.

El sistema funciona por “créditos”, con la equivalencia de **100 crédito = 1 euro**, donde la mayoría de las imágenes de alta resolución están en cifras superiores a los 100000 créditos (1000 euros) por una única imagen ráster. En las Figura 22 y Figura 23 se puede ver como cada satélite, impone también un mínimo o limite en el área para adquirir con unos costes que pueden elevarse exponencialmente.

Sin tener en cuenta el factor económico, esta sería la solución de adquisición de las imágenes con una alta resolución semanalmente/periódicamente para su posterior procesado y control. Las imágenes obtenidas tendrían los parámetros listos y están perfectamente en el estado óptimo para que los códigos presentados en este trabajo actúen debidamente.




Figura 22 Precios de adquisición de SkySat




Figura 23 Adquisición del satélite Airbus Pléiades-Neo

2.3.2 Librerías de código Python para la visión artificial y SIG

Python se ha convertido en uno de los lenguajes preferidos por la comunidad tanto científica, académica y/o público general, gracias a la facilidad de entrada y la cantidad de información que se puede hallar. Es por ello, que el modelo está programado en Python (Python 3.11.9). No solo es el lenguaje preferido, o más común, para la visión artificial sino, que también ofrece una comunidad extensa y proactiva. Además, se encuentran múltiples publicaciones, códigos e información que ofrecen la ayuda necesaria desde los fundamentos básicos de la programación, a algoritmos y tutoriales complejos de las principales arquitecturas de la visión computacional. [66]




Figura 24 Entorno de programación de Python en VSCode

Las principales librerías utilizadas:

- **TensorFlow:** Desde 2015, es una de las bibliotecas de código abierto creada por Google, más utilizadas para el desarrollo de modelos de aprendizaje automático y computación numérica y redes neuronales [67]. En el ámbito del Deep Learning, compite con PyTorch, otra de las bibliotecas de código abierto desarrollada por Facebook, ambas ampliamente en uso en investigación y aplicaciones industriales. Se ha optado por TensorFlow, no por la facilidad de uso, sino por la integración de Keras como API, ya que ofrece una facilidad para el diseño y aprendizaje de los modelos de clasificación de imágenes.
- **Keras:** API de alto nivel que permite construir, modelar, modificar, analizar y realizar el aprendizaje de redes neuronales. [68]
- **Rasterio:** Biblioteca de Python creada para democratizar y adaptar la biblioteca GDAL en un lenguaje e interfaz más pensada en el usuario. Esta librería permite realizar todo tipo de acciones sobre archivos ráster geoespaciales; desde leer, escribir, procesar, modificar, analizar...[69]
- **Geemap:** Librería de Python diseñada por Wu, Qiusheng [70], que permite trabajar en una interfaz visual e interactiva con la aplicación de Google Earth Engine, reduciendo la barrera de acceso a esta. Permite realizar todas las acciones de la plataforma de Google, en un entorno de lenguaje Python, y no en lenguaje JavaScript. Además, esta librería incluye extensos tutoriales, como el mapeado y visualización de ráster geoespaciales que tienen una fuerte conexión con la temática general del TFM. Asimismo, el autor tiene diversos videotutoriales y cursos muy recomendables sobre la programación y el mundo de la teledetección: <https://www.youtube.com/@giswqs>.



Figura 25 Canal de Youtube de Dr. Qiusheng Wu, creador de la librería geemap

2.3.3 Desafíos técnicos presentes

Algunos de los desafíos técnicos que se abordan en este trabajo incluyen:

- La **resolución espacial limitada** de las imágenes satelitales, que dificulta la detección de infraestructuras lineales como líneas de tensión o vías de tren o la presencia de árboles y la distinción con otros tipos de vegetación.
- La necesidad de **datos etiquetados** de alta calidad para entrenar modelos de IA, lo que requiere un esfuerzo significativo en la recopilación y procesamiento de datos. En nuestro caso se creó el conjunto de datos desde cero.
- La **creación y adaptación** de las diferentes **redes neuronales** y algoritmos para conseguir un aprendizaje satisfactorio requieren de una base y conocimiento de programación elevado para su implementación correcta.

2.4 Justificación de la solución adoptada

La solución en forma de aplicación se centra en uno de los ejes o partes del proyecto general ISAPREF de COMSA i la Generalitat de Catalunya, siendo la detección de vegetación como objetivo principal del proyecto. Para ello, al no tener una base de datos o dataset preestablecido, se optó por crear un dataset de imágenes de buena resolución y calidad desde cero. Esta vía permite explorar diversas fuentes de información de ráster, e implementar nuestro propio usando diferentes fuentes, acotar el alcance del objetivo a las zonas de interés y predefinir las clases a analizar. Estas imágenes serán sometidas a los cambios y procesos para su correcta incorporación en el entrenamiento y validaciones de la aplicación. Los modelos utilizados e implementados se caracterizan por ser los modelos que se encuentran ampliamente utilizados por la comunidad de visión artificial así mismo como los ingenieros en teledetección e ingeniería computacional. Es por ello, que se implementaran diversos algoritmos en base Python, para la detección y clasificación, gracias a su facilidad de uso y a un entorno de ejecución más nítido y fácil para los usuarios finales. Estos algoritmos utilizaran las arquitecturas diseñadas para la segmentación semántica, ya que ofrecen una mayor concepción e información espacial y de detalle. Los dos modelos más avanzados que se han explorado han sido basados en las arquitecturas U-Net y DeepLabV3+, los cuales son FCN optimizadas para este campo de la segmentación. Paralelamente, se computarán y ejecutarán otras arquitecturas de redes neuronales con diferentes redes bases ("*backbones*") para analizar las diferentes performances en los resultados y poder realizar un benchmarking de redes neuronales artificiales en nuestro dataset.

Finalmente se prepara la aplicación para poder analizar no solo el rendimiento de la detección de vegetación y otras clases críticas durante el aprendizaje del modelo, sino que también se

ofrecerá una aplicación de búsqueda de zonas críticas por alta presencia de la clase acotada. En nuestro caso, se centrará en las agrupaciones de vegetación o árboles que se encuentren cerca de la red de Infraestructuras (terrestres i viarias). Todo el trabajo pretende servir de guía o pipeline a los usuarios finales, demostrando la viabilidad del uso de la inteligencia artificial juntamente con la teledetección, para su uso final en la prevención de incendios y otros usos en prevención, predicción y prescripción de riesgos a infraestructuras críticas.

3. Metodología aplicada

En este capítulo se mostrará el pipeline esencial previo al entrenamiento final de los algoritmos, desde la obtención de las imágenes ráster, hasta su procesado para su implementación en los modelos de segmentación semántica. Se proporciona los pasos a seguir del programa/aplicación creada, con los inputs necesarios por el usuario.

3.1 Creación del dataset

Al no tener un dataset previo, ni unas limitaciones geográficas acotados, se decidió por crear una colección de imágenes de alta resolución mediante datos satelitales, aéreos y con drones.

Las imágenes provienen de diferentes fuentes de carácter público, de investigación o educacionales, principalmente del catálogo abierto de Google Earth Engine, de imágenes tomadas por la administración pública española (PNOA), así como de imágenes proporcionadas por entidades privadas (Airbus® MAXAR) para la monitorización y postanálisis de la catástrofe natural provocada por la DANA en el País Valencia durante el mes de octubre de 2024. [71], [72]. Las imágenes del dron están realizadas sobre un terreno privado, con presencia de los diferentes elementos de etiquetado seleccionados para las clases de clasificación: Vegetación Alta, Sotobosque o Tierra, Infraestructura...



Figura 26 Imagen de Dron seleccionada para nuestro Dataset. Fuente: Propia.




Figura 27 Esquema de la obtención del conjunto de datos

3.1.1 Imágenes de Dron – Parcela 270 El Puntarró

Se ha utilizado el dron DJI Mini 2, para el uso de recopilar imágenes aéreas de alta resolución, para la creación del dataset, las decenas de imágenes que componen este dataset tienen como objetivo realizar las imágenes con la mayor similitud a las realizadas por satélites de alta resolución RGB, para ello uno de los retos o condiciones es que las imágenes sean tomadas desde una posición lo más vertical al suelo posible. Así se consigue disminuir las discrepancias de ángulos con aquellas tomadas por satélites. El terreno escogido, es un terreno agrícola del municipio de Gorga (Cocentaina), donde se pueden adquirir múltiples ejemplos de los elementos a analizar, en gran importancia la toma de vegetación alta (olivos y pinos), infraestructuras de transporte y diferentes niveles de sotobosque y áridos. Las imágenes captadas tienen una resolución de 4250x2250 píxeles a una resolución de 0.1cm por píxel.



Figura 28 Dron DJI Mini 2 para la adquisición de imágenes



Figura 29 Vista del terreno de pruebas con dron el Puntarró, Gorga. Fuente: Propia

3.1.2 Imágenes aéreas PNOA

Otra fuente de datos para crear el conjunto de imágenes ha sido las imágenes proporcionadas por el Plan Nacional de Ortofotografía Aérea del Gobierno de España, el cual se realiza anualmente a lo largo del territorio con imágenes ráster RGB de alta resolución (0.1m por píxel) y también imágenes en infrarrojo cercano (NIR). El conjunto de datos toma diferentes localizaciones con los elementos seleccionados deseados de puntos de la comarca del Baix Camp, provincias de Lugo y Alicante.




Figura 30 Centro de descargas de las imágenes del PNOA Fuente: pnoa.ign.es



Figura 31 Imagen aérea del dataset de la vía ferroviaria en Lugo. Fuente: PNOA 2021

3.1.3 Imágenes Satelitales

En atención al objetivo y la necesidad práctica del alcance del trabajo, se utilizarán las imágenes de alta resolución provenientes de las diversas constelaciones satelitales disponibles. Para la conformación y procesamiento del conjunto de datos, se obtienen una gran parte de estas gracias al acceso a la plataforma de Google Earth Engine (GEE). Adicionalmente se recurre a las páginas web oficiales de los organismos propietarios de los satélites y de empresas especializadas en la observación de la tierra, tales como UP42, EOPortal, ESACopernicus Satellite Imaging Corp y la aplicación QGIS.




Figura 32 Comparativa de los satélites de observación de la tierra principales

En este trabajo se ha utilizado de este tipo de imágenes ráster de los siguientes satélites:

- **ESA Sentinel-2:** Imágenes de buena resolución multiespectrales (10m RGB)
- **Airbus Pléiades-Neo:** Imágenes de muy alta resolución (0.3m pansharpened RGB).
- **Airbus Maxar (GeoEye y WorldView):** Imágenes de muy alta resolución (0.3m-0.5m pansharpened RGB)
- **PlanetLab SkySat:** Imágenes de muy alta resolución (0.5m pansharpened RGB)
- **21AT Beijing3A:** Imágenes de muy alta resolución (0.5m pansharpened RGB).



Figura 33 Imagen Satelital Airbus Maxar de la parcela Puntarró. Fuente: QGIS

A) QGIS

La plataforma de QGIS (Quantum GIS) es el software gratuito y de código abierto que permite manipular todo tipo de datos de teledetección y ráster geoespacial. Es la alternativa de código público y gratuito a al ArcGIS. En este software permite la exportación de las imágenes ráster de los satélites de Google, ESRI y otras fuentes disponibles, y seleccionar el alcance de las coordenadas de la imagen a procesar. En la Figura 34, se puede ver el entorno de trabajo del programa.




Figura 34 Entorno de trabajo de QGIS

B) Google Earth Engine Platform

La plataforma de Google ofrece un potente entorno computacional en la nube a través de un editor de código integrado en JavaScript. El entorno permite a los usuarios acceder y analizar múltiples catálogos de datos geospaciales, los cuales ya han sido presentados en el capítulo anterior. Mediante el código, se implementan diversos algoritmos y los parámetros necesarios para crear mapas interactivos y ejecutar diversas funciones de análisis sobre estos.




Figura 35 Plataforma de Google Earth Engine

Asimismo, el entorno de *Jupyter-Notebook* es compatible con el editor de código para ejecutar los mismos comandos de la plataforma de *GEE* localmente, empleando las librerías de *geemap* y *earth engine* (ee), que permiten esta manipulación de los datos presentes en la plataforma en la nube, pero con el lenguaje de programación utilizado en el transcurso del trabajo; en Python, sin necesidad del uso de *JavaScript*.




Figura 36 Ejecución de GEE en entorno Python




Figura 37 Mapa personalizado en Python con los datos de GEE

Tras la descarga y guardado de la información ráster de las zonas de estudio, el flujo de trabajo continua con el procesado de los archivos para la segmentación. Siendo clave la creación del conjunto de datos etiquetado, conocido como *ground truth*, el cual es imprescindible para que los modelos sean entrenados y posteriormente analizados a su calidad de reconocimiento de los píxeles y patrones de los elementos etiquetados. [73], [74]

3.2 Máscaras de validación con *ImageJ-LabKit*

El software de *ImageJ LabKit* es una herramienta gratis que permite crear las máscaras de validación o *ground truth* propias para la clasificación [75]. La aplicación es altamente utilizada en el campo de la investigación médica y de datos, ya que su labor principal fue la de crear y procesar conjuntos de datos [76], tarea crítica y muy importante en la detección de células cancerígenas, así como otras enfermedades donde la visión computacional ...[77], [78]. Esta aplicación permite gratuitamente no solamente crear todas las clases de clasificado con su respectivo código de color, si no que incluye un algoritmo de clasificado de píxel automático mediante clasificación por Random Forrest y SVM [79] - [81]. Este aplicativo ya integrado permite ahorrar tiempo de clasificado manual, debido al coste de tiempo y trabajo laborioso que implica clasificar miles de píxeles. No obstante, aquí se encuentra una de las principales advertencias o problemas que hay que hacer hincapié a la hora de prever escalabilidad al aplicativo. Al tener imágenes de alta resolución o imágenes con una gran cantidad de píxeles, es prácticamente imposible clasificar píxel a píxel a la perfección. También hay que añadir que cualquier imagen que se procese, en la mayoría de los casos siempre habrá algún elemento que no esté acotado en nuestra clasificación (coches, basura, tejados, animales...) o elementos que no se pueden distinguir. Estos píxeles serán en la mayoría de los casos acotados con la clase *NoClasificados/Otros*, no obstante, en la creación de las máscaras, ya sea por error humano o la automatización previa, algunos píxeles estarán asociados a clases que no les pertenecen. Aquí se encuentra uno de los retos más importantes y por lo que se ha reiterado en capítulos anteriores, el dataset tiene que ser lo más limpio posible, sin embargo, siempre va a haber ruido, píxeles basura, píxeles que contengan múltiples clases o, errores que en un futuro crearan problemas y/o pérdidas en el entrenamiento del modelo. Si bien es cierto que existen diversos estudios y modelos que pretenden paliar y afrontar este ruido o suciedad en el sistema, mediante diferentes métodos correctivos en todas las fases del entrenamiento, no se encuentran dentro del enfoque y alcance del objetivo. [82], [83]

Estas imperfecciones son comunes en muchos conjuntos de imágenes que se hallan en la comunidad dedicada a la clasificación de cobertura terrestre o al GIS en general. Dos conjuntos representativos serían el conjunto de datos de la ESA (WorldCoverv1) y el UAE Dubái dataset, se observan algunos píxeles no están correctamente clasificados u otra etiqueta se superpone a estos, debido, por ejemplo, a la falta de resolución o generalización del modelo [54], [84], [85].




Figura 38 ESA Clasificación WorldCoverv1 2021 basado en datos Sentinel-2




Figura 39 Dataset de UAE Dubái drone

Volviendo al conjunto de datos propio, estas imperfecciones también estarán presentes. En la Figura 40, se puede apreciar el programa y el resultado de la segmentación semántica semi-manual realizada a una imagen satelital para su máscara *ground truth*.




Figura 40 Segmentación con ImageJ LabKit

Con la ayuda del clasificador integrado en el aplicativo, se obtiene el resultado que se aprecia en la parte inferior de la Figura 40 anterior. En este momento si se analiza el resultado de la clasificación automática integrada por el software (ver Figura 41), se aprecia una de las principales desventajas que se presenta a lo largo de la creación del conjunto de imágenes y máscaras para entrenar los modelos y arquitecturas de segmentación semántica: la calidad y precisión de las máscaras de *ground truth*.




Figura 41 Ampliación de la imagen segmentada por LabKit

Aunque se intente tener la máxima precisión en la máscara *ground truth*, la presencia de falsos positivos es inevitable, debido a la aproximación realizada por el software de preclasificación. Posteriormente a la preclasificación, manualmente se intenta corregir en mayor medida estos defectos, no obstante, es prácticamente inviable debido al alto consumo de tiempo y a las limitaciones propias del programa. Es por eso por lo que debe tener en cuenta de cara a las próximas fases del proceso, que los datos y resultados van a estar afectados por estos desajustes y “falsos-positivos”, que podrán reducir el rendimiento de los modelos analizados entrenados [62]

La clasificación semántica que se ha realizado con los modelos finales, el número de clases se ha fijado en 7:

- **Vegetación Alta/densa:** Formada por árboles y masas de árboles.
- **Sotobosque:** Formada por arbustos y hierba alta.
- **Tierra:** Arena y terrenos áridos presentes. Se generaliza también terrenos de secano con presencia mínima de cualquier tipo de vegetación (hierbas, plantas...).
- **Infraestructura:** Vías de transporte y edificios.
- **Sombra:** Comprende los cuerpos sin luz.
- **Agua:** Cuerpos acuáticos. Es la clase con menos elementos.
- **Otros/NoClasificado:** Todo lo que no está en las otras clases, ruido, objetos/elementos los cuales no tienen una resolución suficiente, coches u dudas en la clasificación.

Núm.	Color		Nombre
0	#009150		Vegetación Alta
1	#90EE90		Sotobosque
2	#FFFF00		Tierra/Áridos
3	#666666		Infraestructura
4	#000000		Sombras
5	#0000FF		Agua
6	#FF0033		NoClassificados/Otros

Figura 42 Información del etiquetado del conjunto de datos




Figura 43 Esquema del proceso de obtención y creación del conjunto de datos



Figura 44 Imagen original de dron.




Figura 45 Imagen etiquetada de dron

3.3 Entorno de la aplicación

Tras tener las localizaciones e imágenes ráster correctamente segmentadas y clasificadas con las etiquetas pertinentes, se procede a crear el conjunto de carpetas y programas que conformaran el conjunto de la aplicación.

Los códigos se han estructurado y comentado en modo de guía, en formato Jupyter Notebook (idéntico a Google Collab), el cual provee de una mayor claridad en la comprensión del código y poder realizar las diferentes secciones o *scripts* por separado para poder analizar que está ocurriendo a cada instante. Debido al tamaño de archivos, se ha decidido guardarlos en el repositorio de GitHub personal, con el fin de habilitar su uso al público y poder optimizarlo y/o mejorarlo de cara al futuro. Siguiendo así, las bases de la filosofía de trabajo en comunidad presente en el entorno de la investigación y el campo de la IA. Así mismo, programadores, investigadores y entusiastas en los diferentes campos de aplicación pueden contribuir a expandir el conocimiento. El dataset original utilizado estará también subido bajo demanda debido al tamaño de los archivos (>20 GB de memoria).




Figura 46 GitHub personal con toda la aplicación de códigos creada

La aplicación final se ha estructurado en 3 partes o fases diferenciadas, siendo estas, las 3 fases del pipeline con sus respectivos códigos y procedimientos. Estas son:

1. **Preparación de los datos:** El primer programa está diseñado para preparar los amplios metadatos de los ráster (tamaño, resolución, bandas multispectrales y canales de color RGB), segmentar y augmentar la imagen original en múltiples

parches 128x128 píxeles para vectorizados para el aprendizaje de los algoritmos de clasificación. (código JavierMCTFM_PreProcess)

2. **Evaluación de los Modelos:** Estos conjuntos de programas realizados para cada arquitectura de red neuronal utilizada (FCNs, UNet y DeepLabV3+), es el corazón de la aplicación. En esta se iniciará el entrenamiento tras compilar toda la información de imágenes y máscaras, se procede a entrenar el modelo con los datos vectorizados en archivos de entrenamiento y validación. Tras el aprendizaje del algoritmo, se exponen las diferentes métricas de evaluación, así como las representaciones del resultado de las predicciones en diversos parches e imágenes.
3. **Predicciones y Uso:** Conjunto de códigos dedicados a la aplicación práctica de los modelos observados:
 - a. *TFM_Test_Javi:* Código dedicado a insertar imágenes para aplicar el modelo entrenado y observar los resultados, comparando la imagen original, con su máscara y predicción según el modelo.
 - b. *TFM_MultiTest_Javi:* Código realizado para crear un mosaico con las diferentes predicciones de diferentes modelos.
 - c. *TFM_Hotspots_Javi:* Código diseñado para analizar en zonas geolocalizadas mediante un polígono cuadrilátero, las zonas con presencia de una clase crítica.




Figura 47 Detección de Vegetación Alta en zonas de interés.

Sumado a las 3 fases anteriores, se han creado códigos y guía para obtener imágenes satelitales de la plataforma de GEE. Este código (*TFM_infoGEE*) podría ser utilizado en el pipeline anterior como obtención regular de datos ráster, previo a la fase de preproceso. Gracias a la ayuda de las librerías de *earth engine* y *geemap*, permiten procesar imágenes de este catálogo y hacer un estudio previo a la clasificación (En las anteriores Figura 36 y Figura 37, se observa esta funcionalidad). Hay que añadir que estas librerías permiten también analizar evoluciones históricas y otros conjuntos de datos, como *ESA_WorldCoverv0* y *ESA_WorldCoverv1* previamente mencionados, que pueden ser muy interesantes, ya que se encuentran muchas imágenes semiclasificadas con una buena precisión general. El abanico de soluciones o de aplicaciones que se derivan, se extiende en un amplio campo según el objetivo y la finalidad en mente como se ha visto en los capítulos anteriores y se discutirá en el final de este.

En la Figura 49 se ha realizado el entrenamiento aplicando el dataset de la ESA (Figura 48). No obstante, esta clasificación tiene muchas más clases y diferente resolución (10m multiespectral). Algunas clases que se pueden ver en la misma podrían ser unidas y/o simplificadas como la clasificación realizada en este trabajo.



Figura 48 Imagen superior: Original Sentinel-2 Baix Camp, Inferior: ESA WorldCover_v1




Figura 49 Predicción con UNet_50Javi entrenada en el dataset WorldCover v1

3.4 Preparación de los datos de aprendizaje

El preproceso es clave y fundamental para obtener un resultado satisfactorio, ya que es la entrada de información al modelo. En esta fase consiste en un código que realiza el procesamiento del conjunto de datos formados por imágenes y sus máscaras etiquetadas previamente (guardadas en carpetas separadas), en archivos de entrenamiento y validación en formato vectorial. Estos últimos archivos son los que la Fase 2 tomará para realizar el aprendizaje de los modelos de segmentación semántica, después de que se les apliquen diferentes transformaciones que se detallaran a continuación.

El script se inicia con la precarga de los archivos de las imágenes, sus *ground truth* y el archivo con las etiquetas y su respectiva paleta de colores. Se carga la imagen original, donde se aplica su normalización RGB a valores entre 0-1. Este procedimiento se aplica a todas las imágenes para que tengan el mismo rango en los canales RGB, ya que muchas imágenes ráster satelitales su rango es de 0-10000, así se asegura que todas las imágenes estén en el mismo rango. Esta normalización también se aplica a las imágenes de dron y aéreas (rango habitual de 0-255). Otra ventaja de la normalización a 0-1, es la mejor eficiencia computacional de los modelos a trabajar con estos valores.[86], [87]

Con la imagen y la máscara representadas, se observará que valores de las clases únicas presentes en la imagen ráster. Aquí es donde el usuario decidirá dependiendo de la preferencia, la cantidad de parches que se realizaran por clase presente. En la experimentación, se ha realizado 20-30 parches por clase, por cada imagen presente en nuestro dataset total. La elección de este número puede debatirse según el tamaño de parche a utilizar para el modelo o la cantidad de información relevante que se pueda extraer de la imagen.

Asimismo, la segunda decisión del usuario se encuentra en el tamaño del parche o *patch* que se utilizará como entrada al modelo.

Seleccionamos las dimensiones de la imagen parche

image_width = 128 #128 o 256 dependiendo de la elección del parche para la red

Cuantificamos el número de parches por clase

num_parches = 30 #Elección del usuario




Figura 50 Representación de la extracción de los parches por clase



Figura 51 Conjunto de parches de la imagen original por clase




Figura 52 Conjunto de parches de la máscara de validación por clase

A todos estos parches se le aplica la aumentación de los datos (**Data augmentation**) [88], [89], [90]. La aumentación de los parches se realiza mediante una serie de 3 rotaciones y giro horizontal a cada uno de ellos, consiguiendo así el objetivo de paliar el sobreajuste, aumentando los datos y la robustez. El proceso permite enseñar al modelo a reconocer el contexto espacial de las clases, así como los cambios en tamaño y posición. Como ejemplo, si se toma un árbol (**Vegetación Alta**), este tendrá que ser identificado como tal, sin que una variación de posición lo afecte. Paralelamente se consigue una reducción en la sensibilidad del modelo a las variaciones y una generalización a nuevas imágenes que entren en el proceso de entrenamiento. Por último, este aumento es beneficioso para las clases con menos presencia, ya que se pueden crear más inputs de dicha clase, mejorando así el aprendizaje de esta. Finalmente, estos últimos archivos contendrán los vectores de información de cada imagen y máscara de validación etiquetada, separados por los conjuntos de datos de entrenamiento y de validación. Estos archivos están correctamente preparados para ser alimentar a los modelos que se han creado. En la Figura 53, se observa el flujo de trabajo de la aplicación con las secciones que se han detallado hasta este punto.




Figura 53 Pipeline de la aplicación desde la adquisición hasta la entrada a los modelos.

4. Resultados

Con todo el conjunto de datos listo para su procesamiento y aprendizaje en las diferentes arquitecturas de clasificación creadas, se presentan los resultados de los diferentes algoritmos que se han diseñado en el transcurso del trabajo.

Para el aprendizaje y compilación del modelo se ha utilizado estos parámetros generales:

- **Optimizador** = Adam. El algoritmo de ajuste de los pesos del modelo más popular y comúnmente utilizado frente a su competencia con *Momentum* y *RMSprop*, ya que combina las ventajas de estos últimos, minimizando la función de pérdida durante el entrenamiento. [91] - [93]
- **Función de pérdida** = *CategoricalCrossEntropy*. Función de pérdida estándar para los algoritmos de segmentación semántica multiclase donde los píxeles solo están unidos a una clase.
- **Tasa de aprendizaje (*Learning rate*)** = 0.001. Valor inicial común. [94]
- **Épocas**: 35. Valor estándar e indicador de estancamiento del modelo.
- **Subdivisión del dataset**: 80% entrenamiento, 20% validación.
- **Métricas de evaluación extraídas**: Exactitud, Precisión, Pérdida, Recall, F1Score y IoU.

```
model.compile(  
    optimizer=keras.optimizers.Adam(0.001),  
    loss=keras.losses.CategoricalCrossentropy(),  
    metrics=[keras.metrics.CategoricalAccuracy(), keras.metrics.MeanIoU(num_classes=num_classes), Recall(), Precision()  
)  
callbacks = [  
    EarlyStopping(patience=5, monitor='categorical_accuracy', restore_best_weights=True)  
)  
result = model.fit(  
    x=images_train,  
    y=mascaras_train_category,  
    epochs= 35,  
    batch_size= 8, #16  
    shuffle=True,  
    validation_split=0.2,  
    callbacks=callbacks,  
    verbose=1,  
)
```

Figura 54 Parámetros de compilación y aprendizaje de los modelos

4.1 Redes Neuronales Convolucionales Completamente Conectadas

Las FCN son la base de las arquitecturas utilizados en la segmentación semántica. Para iniciar la exploración experimental y aprender el funcionamiento de los algoritmos y arquitecturas de las diferentes redes bases. Es muy interesante iniciar en estas estructuras más simples e ir expandiendo a modelos más robustos y complejos como la UNet y DeepLabV3+. Este enfoque permite tener una visión amplia de cómo se estructuran estos algoritmos y que parámetros son interesantes a la hora de obtener unos resultados más satisfactorios, así como testear diferentes modelos y escoger el que proporcione mejores resultados en objetivo final.

Las redes bases FCNs que se han utilizados han sido la arquitectura MobileNetV2 y ResNet50, ampliamente utilizadas en tareas de clasificación de imágenes debido a su relativa facilidad de implementación y reducido costo en recursos computacionales. También hay que destacar que estos algoritmos están mejor optimizados y concebidos para la clasificación y detección de objetos/elementos de imágenes, no para la segmentación semántica a nivel de píxeles.

4.1.1 Estructura FCN con red base MobileNetV2_Javi

La red MobileNetV2, como se ha comentado en el Capítulo 3, ofrece una punta de velocidad computacional y una menor carga de trabajo en los recursos de cálculo. Al igual que con la red base de ResNet50, se programa la arquitectura pre-entrenada de Keras con el datasets ImageNet y sus respectivos pesos, para una inicializar la FCN con un conocimiento previo ya adquirido.

A) Inicio de pruebas piloto pruebas con un dataset reducido y MobileNetV2

En los primeros experimentos se centró en la validación y análisis del rendimiento del modelo de segmentación semántica utilizando imágenes RGB de alta resolución adquiridas con un dron privado DJI en un entorno acotado (parcela Puntarró). Las pruebas se realizaron en dos dataset piloto de 5 y 10 grandes imágenes respectivamente, capturadas a diferentes alturas y ángulos, con el propósito de evaluar la compilación del código y el tiempo de recursos empleado. El uso de la arquitectura MobileNetV2 es utilizada debido a sus propiedades previamente mencionadas y como base previa a otras redes más complejas y computacionalmente más potentes. Los resultados preliminares, evaluados con la métrica del índice de Intersección sobre Unión (IoU), arrojaron una positiva correlación entre el tamaño del conjunto de datos y el rendimiento general de las clases (6 imágenes: IoU de

0.102; 10 imágenes IoU DE 0.389). Es importa señalar que, si bien estas primeras imágenes presentaban diversas perspectivas, se corrigió posteriormente en las próximas fases de experimentación y evaluación para garantizar la coherencia con los conjuntos de datos aéreos y satelitales. A pesar de la simple naturaleza del dataset en tamaño y únicamente 4 clases etiquetadas en las máscaras (Vegetación, Tierra, Sombra, Infraestructura), la tendencia del modelo a identificar patrones y características visuales generales relevantes está altamente presente. Las Figura 55 a Figura 58, se aprecian estas observaciones:




Figura 55 Foto DJI1, 0.102 MIOU Conjunto de datos 6 imágenes




Figura 56: Foto DJI1, 0.386 IoU Conjunto de datos 10 imágenes




Figura 57 Foto vertical DJI524, IoU de 0.102 Dataset 6 imágenes




Figura 58 Foto vertical DJI524, IoU 0.386 Dataset 10 imágenes

Para abordar la experimentación futura y asentar las bases del conjunto de imágenes, se decidió ampliar el dataset con más información y elementos relevantes al objetivo y entorno de trabajo. Para ello era necesario la toma y procesamiento de más imágenes desde las diversas fuentes de información, así como la necesidad de tener la mejor resolución posible y un ángulo de 90° en el caso de los drones. Estas modificaciones dieron como resultado nuestro dataset completo ampliado con las 7 clases etiquetadas que han sido limitadas a las ya presentadas: **Vegetación Alta, Sotobosque, Tierra, Infraestructura, Sombra, Agua y Otros/NoClasificados**




Figura 59 Resultado de segmentación de la prueba piloto en imagen satelital.

C) Modelo MobileNetV2_Javi con dataset ampliado

El primer conjunto de datos extendido se realizó con un dataset original de alrededor de 35 imágenes de alta resolución y de gran cantidad de tamaño. Siguiendo los pasos observados en el capítulo de Preparación del conjunto de datos, se ha procedido a la compilación del modelo MobileNetV2_Javi obteniendo los resultados finales siguientes:




Figura 60 Performance Global de la red MobileNetV2 con el dataset al 75%

En la Figura 62, el rendimiento general se estanca sobre la época 20, donde también se ve ralentizada las mejoras en precisión y en minimización de la función de pérdida. Hay que destacar que la precisión en el entrenamiento se mantiene por encima de la de validación, creando una ligera brecha. No es crítico ni severo, pero es un indicio de que hay un cierto grado de sobreajuste.

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.79	0.84	0.82	22240320
1	#90EE90		Sotobosque	0.68	0.57	0.62	14015508
2	#FFFF00		Tierra/Áridos	0.8	0.9	0.85	19860822
3	#666666		Infraestructura	0.88	0.87	0.88	13890060
4	#000000		Sombras	0.84	0.75	0.79	9573696
5	#0000FF		Agua	0.95	0.61	0.74	17778
6	#FF0033		NoClassificados/Otros	0.85	0.59	0.7	1404312

Figura 61 Resultados del MobileNetV2 con el 75% del dataset




Figura 62 IoU del modelo MobileNetV2 con el 75% del dataset

Muy buenos resultados locales en las dos clases críticas que se quieren clasificar, siendo un 82% en **Vegetación Alta** y un 88% en **Infraestructuras**. Como será común en los modelos presentes, el sotobosque es la clase que menos claridad y precisión se obtienen debido a la gran complejidad de esta y la calidad de los datos entrenados. La media IoU global (0.56) es buena, todo y que muy por debajo del umbral del 0.7 que se desearía obtener. No obstante, se aprecia un buen rendimiento local y global en las clases de **Vegetación**, **Tierra** e **Infraestructura**. Si se analiza juntamente con la matriz de confusión de este modelo entrenado (ver Figura 63), se puede ver como la clase de sotobosque es la que peor resultados está aportando. Esta clase está teniendo conflictos con los píxeles de **Vegetación** y **Tierra**, los cuales son inherentemente similares a esta y donde en el etiquetado original, muchos errores se han ido propagando. Asimismo, esta clase presenta formas y bordes menos definidos y difusos, complicando así que el modelo aprenda correctamente a segmentar estos píxeles.




Figura 63 Matriz de Confusión del Recall de la red MobileNetV2 al 75% del dataset.

En la Figura 64 Parche de Vegetación Alta en dataset MobileNetV2 75% y Figura 66, se tiene la explicación de como en el caso de los pixeles de Sombra, se han identificado con Vegetación. En el etiquetado real, se ha considerado la totalidad del arbol como vegetacion alta, no obstante, se pueden apreciar pixeles más oscuros, estos último son los que han provocado en algunas predicciones el error.




Figura 64 Parche de Vegetación Alta en dataset MobileNetV2 75%




Figura 65 Parche de Infraestructura de MobileNetV2 75%




Figura 66 Ejemplos de clasificados por el modelo FCN-MobileNetv2 75%

D) Modelo MobileNetV2_Javi con el dataset completo

Se procede a entrenar y validar el conjunto de imágenes hasta la totalidad del conjunto etiquetado (más de 50 imágenes), obteniendo los resultados siguientes:




Figura 67 Performance global de la red MobileNetV2 con el dataset completo

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.79	0.81	0.80	29274246
1	#90EE90		Sotobosque	0.67	0.66	0.67	20390190
2	#FFFF00		Tierra/Áridos	0.85	0.85	0.85	27302784
3	#666666		Infraestructura	0.86	0.89	0.88	16470486
4	#000000		Sombras	0.79	0.74	0.77	12887232
5	#0000FF		Agua	0.83	0.74	0.78	25890
6	#FF0033		NoClassificados/Otros	0.82	0.57	0.67	1586964

Figura 68 Resultados del MobileNetV2 con el dataset completo




Figura 69 IoU del modelo MobileNetV2_Javi

Analizando los resultados presentados, el modelo presenta una mejoría general en el rendimiento de segmentación a todos los niveles. Se siguen teniendo los mismos ligeros problemas de un pequeño grado de sobreajuste. No obstante, la mejora continua en el aprendizaje es significativa, obteniendo en las clases críticas unos F1 de 81% en Vegetación Alta (79% anterior) y un 88% constante en Infraestructura, sumado a la mejoría de las otras clases. Sin embargo, y como será una constante en todos los modelos debido a su complejidad y errores/ruidos propagados en el etiquetaje, el Sotobosque será la clase con menos rendimiento y precisión. La media IoU global se ha alzado hasta el 0.66, acercándose al punto de 0.7 deseado.




Figura 70 Matriz de Confusión del MobileNetV2_Javi

Se continúa observando la misma tendencia al error en la clasificación del Sotobosque y la Sombra con sus clases más similares.

A continuación, se presentan una serie de segmentaciones realizadas a diversas imágenes de diferentes fuentes para observar el modelo en acción:




Figura 71 Conjunto de imágenes segmentadas por el modelo MobileNetV2_Javi

En resumen, los resultados indican que la arquitectura MobileNetV2 proporciona una buena clasificación de las clases críticas principales, **Vegetación e Infraestructura**, representados en los indicadores de F1Score y IoU positivos obtenidos. La media de 0.6552 en el conjunto de datos total, indica que el modelo está en buenos niveles competitivos, no obstante, se señala la necesidad de mejorarlo a un umbral superior al 0.7. Sin embargo, se demuestra la capacidad del modelo a identificar las clases con precisión y de manera robusta.

Se procederá ahora a analizar las otras redes FCN derivadas como la ResNet50, U-Net i finalmente la DeepLabv3+, donde se visualizará comportamientos similares y se refinará la escalabilidad de la solución, dando respuesta a como se debería tratar esta aplicación en un futuro. Como será patrón en todas las redes, el factor crítico y limitante de la aplicación es la calidad del conjunto de datos con el cual se pretende que aprenda el modelo, si no está perfectamente creado, la propagación de errores y el sesgo se incrementarían sustancialmente.

4.1.2 Prueba de la arquitectura modelo FCN_ResNet50_Javi

Con los mismos parámetros de entrada y filosofía en la selección de los bloques para extracción de características como se usó con la red base MobileNetV2, se codifica el algoritmo con ResNet50 para visualizar el rendimiento de este modelo.

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.40	0.88	0.55	29274246
1	#90EE90		Sotobosque	0.29	0.18	0.22	20390190
2	#FFFF00		Tierra/Áridos	0.66	0.33	0.44	27302784
3	#666666		Infraestructura	0.59	0.41	0.49	16470486
4	#000000		Sombras	0.56	0.24	0.34	12887232
5	#0000FF		Agua	0.00	0.00	0.00	25890
6	#FF0033		NoClassificados/Otros	0.42	0.04	0.07	1586964

Figura 72 Rendimientos del modelo ResNet50




Figura 73 IoU del modelo ResNet50

Como se puede observar en las predicciones realizadas, el modelo no se está entrenando correctamente con el conjunto de datos alimentado. La tabla con los parámetros de rendimiento muestra esta disparidad de resultados y una caída general del rendimiento global y particular por clase.

La explicación de estos resultados radica en la mala configuración de este modelo para este conjunto de datos, donde los bloques seleccionados para la extracción de información seguramente no son los indicados, errores en la programación o el requerimiento adicional de modificar los parámetros de entrenamiento y la pérdida de información en su transcurso.

Aunque esta red neuronal no haya sido satisfactoria, no es ningún problema, ya que para las tareas de segmentación semántica que se pretende realizar, existen más arquitecturas más robustas y dedicadas como son la UNet y DeepLabv3+, los cuales se explorarán a continuación. Estos futuros modelos serán la solución adoptada para la aplicación.




Figura 74 Aplicación del modelo ResNet50_Javi

4.1.3 Arquitectura modelo UNet_Javi

Después de la experimentación con las FCNs con diferentes tipos de redes bases como MonbilenetV2 y ResNet50, se optó por crear una red neuronal con arquitectura UNet para el objetivo final, dado las buenas prestaciones que esta presenta y siendo esta arquitectura una de las más importantes en los problemas de segmentación semántica.

Para analizar los resultados, se realizó el aprendizaje de esta red con diferentes tamaños de dataset. Así se tiene una vista general de como el modelo progresa según la cantidad de datos introducida en el aprendizaje y cuáles son las ventajas y los inconvenientes surgidos.




Figura 75 Arquitectura de UNet_Javi utilizada

A) Unet10_Javi

Este conjunto de datos básico y el más limitado, fue el inicial de prueba de concepto, el cual se utiliza como inicio de la experimentación para observar la evolución del aprendizaje de la red UNet y depuración del código.

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.87	0.91	0.89	7144512
1	#90EE90		Sotobosque	0.84	0.76	0.8	6346200
2	#FFFF00		Tierra/Áridos	0.84	0.85	0.85	5599572
3	#666666		Infraestructura	0.91	0.93	0.92	3759756
4	#000000		Sombras	0.89	0.94	0.91	3208428
5	#0000FF		Agua	0	0	0	0
6	#FF0033		NoClassificados/Otros	0.86	0.69	0.76	287004

Figura 76 Rendimiento del modelo UNet_10




Figura 77 IoU del modelo UNet10

Los resultados dan una clara visión de que el modelo está ligeramente aprendiendo, pero, lejos del objetivo real con el tamaño de información que se le está ofreciendo. Principalmente la gran disparidad entre el F1-Score i la IoU, fundamentada en que el modelo está empezando a correctamente clasificar pixeles a nivel individual (F1 alto, Recall y Precisión alto), pero que los detalles finos y las características entre diferentes clases es muy deficitaria (IoU bajo). Esta falta de variabilidad en el dataset provoca estos resultados tan desequilibrados. Es más, se observa que, durante el entrenamiento, el dataset no presentaba ningún píxel de la clase Agua, ya sea porque los parches de entrenamiento no los contenían o no había presencia de Agua en este conjunto. No obstante, se observa el potencial de esta arquitectura si se analiza los resultados de las predicciones realizadas a diferentes imágenes, como se expone en la Figura 78. Se observa como en algunas imágenes más “simples”, el

modelo es capaz de detectar la mayoría de las clases y se aprecia una primera aproximación a aprender características medias y finas como son la iluminación, textura y bordes entre clases.




Figura 78 Predicciones con UNet10_Javi

B) UNET20_Javi

Se amplia el conjunto a 20 imágenes ráster:

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.87	0.85	0.86	15485736
1	#90EE90		Sotobosque	0.73	0.72	0.72	11490168
2	#FFFF00		Tierra/Áridos	0.86	0.88	0.87	14476008
3	#666666		Infraestructura	0.92	0.92	0.92	6003780
4	#000000		Sombras	0.84	0.88	0.86	6315870
5	#0000FF		Agua	0.99	0.94	0.96	17778
6	#FF0033		NoClassificados/Otros	0.95	0.77	0.85	867684

Figura 79 Rendimiento del modelo UNet20




Figura 80 IoU del modelo UNet_20

Se obtiene una mejora general en todas las clases (F1 altos), fruto de una mejor generalización y aprendizaje de bordes (**IoU 0.5382** > 0.3203) . La cantidad de datos de entrenamiento es uno de los factores clave para la mejora, repercutiendo en la identificación correcta de clases más heterogeneas como la **NoClasificado** y la nueva inclusión de los píxeles de la clase **Agua**. La imágenes presentes en la Figura 81, confirman esta evolución y segmentación más detallada en todas las clases presentes.




Figura 81 Resultados del modelo UNet20_Javi

C) UNet30_Javi

Se amplia el conjunto de datos a 35 imágenes, obteniendo los resultados siguientes:

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.82	0.89	0.85	22240320
1	#90EE90		Sotobosque	0.71	0.64	0.67	14015508
2	#FFFF00		Tierra/Áridos	0.86	0.88	0.87	19860822
3	#666666		Infraestructura	0.92	0.9	0.91	13890060
4	#000000		Sombras	0.87	0.86	0.87	9573696
5	#0000FF		Agua	0.97	0.96	0.97	17778
6	#FF0033		NoClasificados/Otros	0.91	0.59	0.72	1404312

Figura 82 Rendimiento del modelo UNet30




Figura 83 IoU del modelo UNet30

Se continua logrando una mejor robustez y capacidad de generalización, con una ligera subida de la IoU global al 0.618. Las clases críticas y predominantes para el objetivo final (**Vegetación Alta**, **Infraestructuras**, **Tierra**) se consolidan en rendimientos muy positivos en todas las métricas de evaluación. También es notable la mejora en las clases más desafiantes (**Sotobosque**, **NoClasificados**), aunque mantienen resultados por debajo de la IoU del 0.5.




Figura 84 Resultados del modelo UNet30_Javi

D) UNet50_Javi

Finalmente se realiza el entrenamiento del modelo con la totalidad del conjunto de datos:

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.82	0.83	0.82	29274246
1	#90EE90		Sotobosque	0.69	0.62	0.65	20390190
2	#FFFF00		Tierra/Áridos	0.8	0.89	0.84	27302784
3	#666666		Infraestructura	0.9	0.84	0.87	16470486
4	#000000		Sombras	0.8	0.84	0.82	12887232
5	#0000FF		Agua	0.97	0.96	0.96	25890
6	#FF0033		NoClasificados/Otros	0.89	0.53	0.66	1586964

Figura 85 Rendimiento del modelo UNet50_Javi




Figura 86 IoU del modelo UNet50_Javi

Se continua logrando una mejora sustancial en la métrica más restrictiva en la segmentación (IoU), generando una mejor robustez y generalización, alcanzando prácticamente el umbral de una media IoU global ≥ 0.7 . Todas las clases, a excepción del **Sotobosque** y **NoClasificados** logran un $F1 > 0.8$ y una $IoU > 0.7$, demostrando una calidad alta de segmentación y un rendimiento competitivo. Si se realiza la matriz de confusión (Figura 87) para esta arquitectura y dataset, se observa que efectivamente la clase de **Sotobosque**, tiene tendencia a perder calidad de clasificación, entrando en conflicto con la **Vegetación Alta** y la **Tierra**, mientras que la clase **NoClasificado**, entra en conflicto principalmente con **Infraestructuras**. En la clase **Sotobosque**, viene dado por la similitud entre clases y el error en el etiquetado de estas, debido a que en el preproceso es muy posible que zonas de hierbas, matorales (clase principalmente **Sotobosque**) se hayan considerado de una clase diferente. En el caso de **NoClasificados**, el conflicto normalmente viene a raíz de la presencia de vehículos, edificios o elementos ajenos que se encuentran en las imágenes cerca o dentro de carreteras o vías de tren, lo cual afecta en el aprendizaje del modelo.




Figura 87 Matriz de confusión de píxeles en UNet50_Javi




Figura 88 Resultado del modelo UNet50_Javi img40




Figura 89 Resultado del modelo UNet50_Javi img10




Figura 90 Resultados del modelo UNet50_Javi




Figura 91 Evolución de la IoU por clases según tamaño de dataset




Figura 92 Evolución de la F1Score por clase y global según el tamaño del dataset

Como se puede apreciar en las anteriores gráficas y en los resultados que se han ido observando durante los diferentes tamaños, se concluye que la arquitectura aprende satisfactoriamente a medida que el conjunto de datos aumenta. El mayor volumen y diversidad de los datos permite enriquecer al modelo, consiguiendo captar patrones generales y complejos, así como los detalles de más finos y característicos de las clases etiquetadas a segmentar.

La métrica más restrictiva como es la IoU media global tiene tendencia ascendiente y positiva (de 0.3062 a **0.6904** al escalar de 10 a 50 imágenes respectivamente), es la prueba de que el modelo está logrando un aprendizaje robusto y continuo en la capacidad de segmentación a nivel de píxeles. La **Vegetación Alta** y la **Infraestructura**, las dos clases principales del trabajo obtienen un resultado particular de **0.701** y **0.774** respectivamente, resultados que se encuentran en un rango muy notable, si se compara con los grandes datasets de imágenes para competiciones de segmentación y clasificación de imágenes como: PascalVOC (media IoU: 0.89 en 2018 [95] y 0.62 en 2015 [20]), dataset DeepGlobeV1 (media IoU: 0.545 [96]), Cityscapes (media IoU: 0.867 en 2023 [40], [97]), ADE20K (media de 0.452 en 2021 [98], [99]). El resultado final se encuentra entre los valores estándares y considerados como el benchmarking actual, teniendo en cuenta no solo el tamaño de dataset, sino que también por la calidad de las imágenes y la cantidad de clases a segmentar.

Si que es cierto que, el F1-Score decrece ligeramente, tanto el de por clase y el global (0.86 a 0.81), no obstante, se mantiene alto y en un rango muy notable (0.82 en **Vegetación Alta** y 0.87 en **Infraestructura**). Esta bajada se debe principalmente al desbalanceo de las clases presentes, así como una focalización más precisa en la delimitación y generalización de las clases dominantes y principales, lo cual generaría peor precisión y *Recall* en las clases menos balanceadas.

4.1.4 Arquitectura modelo DeepLabV3_Javi

Para concluir con la experimentación, se entrena el modelo con la última arquitectura estudiada, para evaluar su rendimiento con nuestro dataset y la configuración de parámetros realizada en este trabajo.




Figura 93 Evolución del aprendizaje de la red DeepLabV3+_Javi

Núm.	Color		Nombre	Precision	Recall	F1Score	Pixel Support
0	#009150		Vegetación Alta	0.8	0.86	0.83	29274246
1	#90EE90		Sotobosque	0.74	0.71	0.72	20390190
2	#FFFF00		Tierra/Áridos	0.87	0.9	0.88	27302784
3	#666666		Infraestructura	0.92	0.9	0.91	16470486
4	#000000		Sombras	0.87	0.75	0.8	12887232
5	#0000FF		Agua	0.94	0.96	0.95	25890
6	#FF0033		NoClassificados/Otros	0.81	0.73	0.77	1586964

Figura 94 Métricas del modelo DeepLabV3+_Javi




Figura 95 IoU del modelo DeepLabV3+_Javi

Como se aprecia en las Figuras y Tablas de evaluación anteriores para esta arquitectura, se demuestra otra vez, que el aprendizaje es robusto y con mejora continua a lo largo de las épocas de entrenamiento. Asimismo, se denota una mejoría ligera en las clases respecto a las otras arquitecturas presentadas, obteniendo los valores de IoU por clase y global más alta **0.756**. Las clases objetivo **Vegetación Alta** e **Infraestructura** consiguen obtener unos niveles por clase competitivos y muy buenos en segmentación semántica ($F1 > 0.8$) al igual que una IoU más restrictiva y atenta a los contornos de las clases superior al 0.7. Otro dato curioso es el mejor rendimiento general de las clases más afectadas por el desbalance de representación y la presencia de ruido y/o sesgo en el etiquetaje (**Sotobosque** y **Sombra**), las cuales también presentan valores muy aceptables. El único inconveniente de esta red es que aun teniendo los módulos ASPP que permiten una mejor extracción, sin afectar demasiado a la carga computacional, los tiempos de entrenamiento de la red DeepLabV3 son muy superiores a las anteriores. Normalmente, usando los equipos de cálculo propios, el tiempo por época de entrenamiento no baja de 55 minutos, mientras que la red *UNet_Javi* se encontraba sobre los 30 minutos.




Figura 96 Ejemplos de predicción modelo DeepLabV3+_Javi




Figura 97 Resultados del modelo DeepLabV3_Javi




Figura 98 Más resultados del modelo DeepLabV3+_Javi

4.2 Entorno de aplicación, escalabilidad y mejoras

Con los modelos ya entrenados y validados, se ha creado un conjunto de códigos que permiten observar la aplicación en un entorno operativo.

4.2.1 Detección de Vegetación e Infraestructura

El objetivo principal de este trabajo ha sido el estudio de viabilidad de detección o segmentación de vegetación mediante diferentes métodos de obtención, particularmente satelitales. Como se ha podido observar a lo largo de la Memoria Técnica, se ha conseguido enseñar a diversos modelos y arquitecturas ampliamente utilizados en el campo de la Inteligencia Artificial, segmentar diferentes clases etiquetadas, entre ellas nuestro objetivo principal: la **Vegetación Alta**. La disponibilidad de estas imágenes de alta resolución de observación de la tierra satelitales ha demostrado ser limitado debido al alto coste económico y/o de la no disponibilidad de fuentes públicas de alta resolución. No obstante, con la ayuda de las imágenes aéreas y de drones, se puede conseguir complementar el dataset óptico satelital con más imágenes para el aprendizaje.

En el código *TFM_Hotspots_Javi* se ha diseñado para que procese una imagen segmentada y permita detectar agrupaciones significativas de cualquier clase etiquetada en un polígono seleccionado. En el siguiente ejemplo se ha tomado el resultado de la segmentación mediante DeepLabV3 de una imagen satelital de alta resolución (0.1m por píxel), la cual se desea detectar árboles comprendidos en un área delimitada.



Figura 99 Zona de análisis acotada con las agrupaciones objetivos

Para ello el sistema está preparado para que el usuario inicialice no solo la información del polígono cuadrilátero, sino que también pueda especificar el umbral de píxeles que desea tener la alerta.

```

-0.36110525456337195 38.723732087134586, -0.36037837592033606 38.72397901146218, -0.36057
Formato: 'Lon1 Lat1, Lon2 Lat2, Lon3 Lat3, Lon4 Lat4': (Press 'Enter' to confirm or 'Escape' to cancel)

--- Analizando presencia de agrupaciones de 'Arboles' en el polígono ---
Polígono de entrada: [(-0.36110525456337195, 38.723732087134586), (-0.36037837592033606, 38.72397901146218),
Umbral mínimo de píxeles: 5000
Coordenadas transformadas de EPSG:4326 a EPSG:3857

¡Presencia detectada! Se encontraron 12 agrupaciones de 'Arboles' por encima del umbral de 5000 píxeles.
La agrupación más grande encontrada tiene 22422 píxeles contiguos.

```

Figura 100 Segmento de la aplicación de detección para la Vegetación Alta

El código aplica esta información y devuelve delimitados las áreas de píxeles que contienen este elemento en el umbral asignado. Como se observa en la imagen siguiente se han detectado 12 agrupaciones de Arboles con más de 5000 píxeles. Esta información estará disponible en el programa y automáticamente generará un archivo .CSV para su tratamiento posterior si se requiere por el usuario o cliente.

Este código está dispuesto para que el usuario lo mejore y realice el *fine-tuning*, para su aplicación en mente, siendo esta la elección de la clase a analizar, que umbrales de píxeles

son adecuados, como representar estos elementos en las gráficas... Así mismo, el usuario puede evaluar más en detenimiento la calidad de la segmentación realizada, si observa por ejemplo la Figura 104, que hay errores en la clasificación (píxeles de vegetación clasificados, pero deberían de ser otra clase) y así mejorar el dataset de entrada. Y esto forma parte del principal problema que se ha ido comentando a lo largo del trabajo sobre los errores, el ruido y la calidad del dataset. Al fin y al cabo, las máscaras de *ground truth* (ni las presentes en los datasets públicos) nunca serán 100% correctas, más los errores de aprendizaje inevitables por las arquitecturas de redes neuronales artificiales. No obstante, se observa que la aplicación resuelve **muy positivamente** nuestro objetivo, clasificando con buena precisión los elementos (o clases) clave y que se puede realizar un post-procesado que permita realizar comandos de actuación en las zonas críticas a proteger o prevenir cualquier riesgo.




Figura 101 Zona objetivo de umbral de 5000 Píxeles (12 detecciones)




Figura 102 Zona objetivo-ampliada con un umbral de 1000 píxeles (27 detecciones)

D9						
	A	B	C	D	E	F
1	ID_Agrupacion	Clase	Tamaño_Pixeles	Centro_Fila_Pixel_Absoluto	Centro_Columna_Pixel_Absoluto	Centro_Longitud_Geografica
2	1	Arboles	16535	140.44	1699.02	-40140.25422
3	2	Arboles	15669	197.77	1588.09	-40151.34634
4	3	Arboles	4444	181.91	1407.62	-40169.39274
5	4	Arboles	3638	211.2	1514.56	-40158.69892
6	5	Arboles	7308	261.88	1281.53	-40182.00083
7	6	Arboles	1278	234	1851.42	-40125.01525
8	7	Arboles	8239	298.9	1812.12	-40128.94523
9	8	Arboles	6524	282.7	1470.38	-40163.11677
10	9	Arboles	3364	273.32	1187.5	-40191.40357
11	10	Arboles	1921	274.9	1360.53	-40174.10109
12	11	Arboles	1990	284.24	1721.99	-40137.9573
13	12	Arboles	8601	342.41	1098.69	-40200.2842
14	13	Arboles	2952	334.86	1398.2	-40170.33473
15	14	Arboles	11112	413.04	1240.64	-40186.08984
16	15	Arboles	9072	412.88	1549.19	-40155.2364
17	16	Arboles	6065	383.16	924.41	-40217.7113
18	17	Arboles	2076	372.93	1317.35	-40178.41902
19	18	Arboles	6291	390.34	1681.86	-40141.9697
20	19	Arboles	2227	392.73	1467.24	-40163.43142
21	20	Arboles	22422	511.13	1130.81	-40197.07189
22	21	Arboles	2981	424.62	1404.83	-40169.67169
23	22	Arboles	6060	472.33	983.61	-40211.7919
24	23	Arboles	1263	456.76	1345.53	-40175.60125
25	24	Arboles	4036	500.4	1421.7	-40167.98514
26	25	Arboles	2140	534.88	1335.05	-40176.64932
27	26	Arboles	3863	564.75	1075.23	-40202.63006
28	27	Arboles	3200	570.76	1249.46	-40185.20754
29						
30						

Figura 103 Fichero con la información de detección de las 27 detecciones previas




Figura 104 Ejemplo de detección de vegetación en imagen satelital 029




Figura 105 Ejemplo de detección de vegetación en imagen satelital 024




Figura 106 Representación general del flujo de la aplicación

4.2.2 Otras aplicaciones práctica y escalabilidad: Mapeado de catástrofes, fenómenos meteorológicos y eventos temporales:

El trabajo realizado en la Memoria Técnica centrado en la segmentación semántica de vegetación mediante diferentes algoritmos del aprendizaje profundo (DL), ha seguido una metodología y un procesamiento robusto y estándar que tiene más usos y derivaciones que el mío propio. Si se tiene en cuenta la naturaleza de los modelos y arquitecturas de redes neuronales artificiales utilizadas, el abanico de soluciones se puede expandir al modificar por ejemplo el tipo de dataset de entrada (con sus características singulares) o modificando parámetros adicionales. Por ejemplo, como se ha podido ver en el Capítulo 2 de Fundamentos Teóricos, se encuentran diferentes datasets i modelos que pretenden analizar el NDVI (Índice de Vegetación de Diferencia Normalizada), el cual ofrece información sobre el estrés hídrico de las masas de vegetación. Este parámetro bien entrenado, podría dar no solo información de la salud y densidad de la vegetación, sino que también sirve como evaluación del estado de sequedad del terreno, el cual permite predecir los riesgos de ignición y propagación de incendios e inundaciones [59], [61], [62], [65], [100] . Estos datos se pueden obtener de los satélites públicos como el Sentinel-2 y Landsat-8, los cuales ofrecen una gran cantidad de información para poder procesar, analizar y crear soluciones propias.




Figura 107 Mapa NDVI con los incendios en el oeste de Turquía. Fuente:[62]

Otra aplicación usando los datos de teledetección de los sensores térmicos, como los proporcionados por los satélites MODIS, ofrece información clave sobre anomalías térmicas en los terrenos y zonas de mayor susceptibilidad a incendios.




Figura 108 Zonas de alta temperatura urbana en Madrid. Fuente: ESA

Una aplicación de la metodología muy interesante y en este caso, también con el uso del dataset creado ha sido el análisis de las afectaciones de eventos extremos pasados como la DANA de Valencia de 2024 [71]. Este fenómeno meteorológico causó diversos daños materiales en las infraestructuras altamente visibles. En la Figura 110, Figura 111, Figura 112 y Figura 113, se pueden apreciar los múltiples cambios en el terreno provocados por este evento, tales como la acumulación de barro y tierra en amplias zonas, la pérdida de masa vegetal sana, así como la desaparición de la autopista, al ser completamente colapsada por el barro. Esta capacidad para analizar y visualizar imágenes ópticas que permiten evaluar los impactos de eventos reafirma esta idea de escalabilidad y expansión de la metodología para la gestión de desastres naturales y las consecuencias en el terreno. Con toda esta información estructurada y preparada en mano, se otorga a los usuarios una herramienta de apoyo en la toma de decisiones y gestionar, prescribir acciones para la protección de infraestructuras críticas.




Figura 109 Predicción de nuestro dataset en los eventos de la DANA




Figura 110 Imagen satelital previa a la DANA. Fuente Airbus Maxar y Propia




Figura 111 Imagen satelital posterior a la DANA. Fuente Airbus Maxar y Propia




Figura 112 Imagen satelital n2 previa a la DANA. Fuente Airbus y Propia




Figura 113 Imagen satelital n2 posterior a la DANA. Fuente Airbus y Propia

5. Valoración económica e impacto medioambiental

5.1. Costes

A continuación, se presentan los costes actuales de la realización del trabajo. Se ha tenido en cuenta los equipos de computación utilizados, equipos de captura de imágenes, softwares y el coste personal de trabajo.

Unidad	Concepto		Coste €
1	MSI GF63 con GPU 1080GTX		700.00 €
1	MSI Katana 15 GPI 4060RTX		1,350.00 €
1	DJI Mini 2		600.00 €
1	Subscripción Google Drive (200Gb)		31.84 €
Trabajador	Tiempo del TFM (h)	Salario (€/h)	
Ingeniero Industrial	902	13.5	12,177.00 €
TOTAL (Base Imponible):			14,858.84 €
IVA (21%)			3,120.36 €
TOTAL			17,979.20 €

Figura 114 Desglose de costes

5.2. Impacto Medioambiental

El desarrollo de este proyecto de Final de Máster ha implicado una serie de impactos medioambientales tanto directos como indirectos, derivados principalmente del uso intensivo de recursos computacionales para el procesamiento de los grandes conjuntos de datos. Hay que tener en cuenta que los conjuntos de datos están formados por imágenes de alta resolución y de una cantidad de metadatos muy importante. Siendo la procedencia de estos abarca diferentes fuentes, desde plataformas de adquisición privadas (drones) hasta programas de observación de la Tierra de acceso público y privado. El impacto medioambiental se puede derivar en dos categorías siendo estas el impacto local o directo, y el indirecto:

- Desde una perspectiva de impacto **directo**, el entrenamiento, procesamiento y análisis de los resultados de los modelos de clasificación ha requerido un uso intensivo y prolongado equipos locales, tanto Unidades Centrales de Procesamiento (*CPUs*) como Unidades de Procesamiento Gráficas (*GPUs*), en un entorno local. Concretamente, la mayor parte de las operaciones se ha realizado mediante la GPU de un portátil personal, NVIDIA RTX4060 con 16GB de memoria. Además, que, durante los primeros meses del trabajo se usó una GPU NVIDIA GTX 1080 de 8GB integrada en un portátil más antiguo, el cual se quedó completamente obsoleto para las tareas requeridas en esa Tesis de Máster.

Los procesos relacionados con las fases de entrenamiento de algunos modelos con las arquitecturas más complejas como las redes U-Net y DeepLabV3+, como se ha observado y detallado en capítulos previos, implicaron sesiones de cómputo que en la mayoría de los casos superaron las 12 horas continuas a pleno rendimiento de los equipos. Este uso prolongado conlleva un alto consumo energético que se ha cuantificado y que se ha estimado en el capítulo 5.2.1.

- En el impacto puramente **indirecto**, se destaca la dependencia en los servidores y centro de datos perteneciente a plataformas como Google Earth Engine, el portal de la Agencia Espacial Europea (ESA) para las misiones Copernicus (Sentinel, MODIS...), otras entidades de la industria geoespacial (UP42, Airbus...). La disponibilidad y acceso a las extensas colecciones de imágenes de observación de la Tierra de alta cantidad de información y calidad son sustentadas por una infraestructura de almacenamiento, procesamiento y distribución en grandes centros de datos y servidores de las empresas previamente mencionadas. Estos centros de datos, hoy en día en el eje de muchas miradas, son sistemas de gran consumo de energía y de recursos para su correcto funcionamiento. Siendo estos requerimientos energéticos comparables al consumo de ciudades enteras [101]. No es solo el uso de electricidad como vector energético, si no el amplio consumo de agua, para la refrigeración de los equipos.

No solo estos centros se dedican exclusivamente al análisis geoespacial o de monitorización de los sistemas terrestres (temperatura, incendios, agricultura...). También sustentan el funcionamiento de la información que se encuentra en la red y se utiliza globalmente, sino que actualmente alojan y ejecutan los famosos modelos de lenguaje (LLMs), más comúnmente utilizados como ChatGPT, GeminiAI o DeepseekR3, donde los usuarios pueden realizar diversas consultas, crear imágenes y videos, presentaciones o simplemente interactuar. Cualquier de estas últimas interacciones, muchas veces triviales y sin ningún propósito actual, implican un consumo de recursos por parte de estos servidores para generar unas respuestas, generando una ineficiencia de la infraestructura.

Si bien existe la justificación y perspectiva de que el sistema global de la IA; servidores, centros de datos y modelos, adoptan o dicen querer adoptar su energía de fuentes renovables y aumentar la eficiencia de los sistemas [102], [103], [104], pero la realidad es que aún quedan mucho camino en para reducir los enormes consumos de recursos energéticos y hídricos usados por estas entidades privadas. [101]

En general, es crucial comprender que cualquier uso de modelos en la Inteligencia Artificial y sus diversas aplicaciones, como los modelos de Deep Learning empleados en esta disertación para la clasificación y segmentación de imágenes, conlleva un coste ambiental intrínseco que a menudo se tiende a subestimar y omitir. Finalmente, es necesario reiterar en este capítulo, la necesidad de crear los conjuntos de datos con una estructura y correctamente etiquetados en su mayor medida. La eficiencia y rendimiento general del sistema mejora cuando los datos procesados están correctamente procesados, eliminando ruido y sesgo innecesario, así como disminuyendo el impacto negativo al medio ambiente evitable.

5.2.1 Cálculo del impacto

Tomando como referencia el consumo de la GPU (RTX4060) estimada en 130W, las horas en uso y el último factor de emisión del mix energético español es de 0.283 kgCO₂/kWh, resulta [105], [106], [107]:

$$130W * 884h = 114920 Wh = 114.92 kWh$$

$$114.92 kWh \times \frac{0.283 kgCO_2}{kWh} = 32.52 kgCO_2$$

El impacto ambiental directo generado por emisión de CO₂ es de **32.52kgCO₂**, el cual es bastante pequeño y usual en este tipo de trabajos. No se tiene en cuenta las emisiones indirectas ya que estas están fuera del alcance.

6. Conclusiones

Tras la realización de este Trabajo de Fin de Máster, se han extraído las siguientes conclusiones:

- 1- **Necesidad de la creación de un conjunto de datos para la experimentación:** Se ha desarrollado un conjunto de datos específico para la detección de vegetación mediante algoritmos de segmentación semántica multiclase. Esta aplicación o programa con el dataset incluye siete clases diferenciadas: **Vegetación Alta**, **Sotobosque**, **Tierra** o áridos, **Infraestructura**, **Sombra**, **Agua** y **NoClasificados/Otros**. Este conjunto acotado y limitado es el recurso fundamental para entrenar y validar los modelos de visión artificial dedicados a la segmentación semántica de píxeles en el análisis de la teledetección con el fin de lograr el objetivo propuesto.
- 2- **Evaluación de arquitecturas de segmentación actuales:** Se han evaluado diversas arquitecturas de redes neuronales, como U-Net, DeepLabV3+ y FCN básicas (basadas en MobilenetV2 y ResNet50), utilizando los parámetros de aprendizaje necesarios con resultados muy positivos. Las pruebas experimentales han permitido comparar el rendimiento de los modelos, extrayendo recomendaciones y escalabilidad para futuras mejoras, identificando las ventajas y las limitaciones de cada enfoque.
- 3- **Rendimiento y precisión global alcanzada satisfactoriamente:** Se ha logrado en los modelos UNet y DeepLabV3+ un **rendimiento global** de las 7 clases del **73%** y **69%** en IoU respectivamente, y en las clases críticas un F1Score del **83%** en **Vegetación Alta** y un **91%** en **Infraestructura**.
Los resultados refuerzan la viabilidad de utilizar estas técnicas del Aprendizaje Profundo englobadas en la Inteligencia Artificial para la detección de vegetación, más otros elementos u objetos en imágenes satelitales y aéreas con el fin de predecir y prevenir riesgos a las infraestructuras.
- 4- **Altas limitaciones y costes en la adquisición de ráster de satélites de alta resolución:** La adquisición de las imágenes ópticas de alta resolución se encuentra muy limitada debido a una gran barrera económica e institucional. Su implementación no es viable dentro del marco de este trabajo de máster, tanto por razones económicas como por los costes logísticos de procesamiento de imágenes, al no haber un dataset previo. No obstante, se han incorporado con éxito diversas imágenes de alta resolución satelitales de acceso público al dataset de prueba.
- 5- **La aplicación de los de satélites de acceso público:** Los satélites Sentinel-2 y la constelación Landsat proporcionan imágenes multiespectrales semanalmente con resoluciones de 10 y 30 metros respectivamente. No son ideales si se pretenden clasificar elementos con un alto nivel de detalle como pueden ser árboles, torres de

alta tensión... A pesar del menor nivel de detalle, son esenciales para la detección de cambios en el terreno, estado de vegetación y variables térmicas. La Inteligencia Artificial puede facilitar técnicas y soluciones para la prevención, predicción y evaluación de riesgos dependiendo del objetivo planteado y la arquitectura de los algoritmos programados.

- 6- **Gran utilidad y beneficios en el uso de drones para la creación la adquisición de imágenes:** Los drones han demostrado ser una fuente de toma de imágenes aéreas extremadamente precisa y versátil. Su capacidad para capturar imágenes de alta resolución a bajo costo los convierte en una herramienta muy interesante para la creación, mejora y complementación de los conjuntos de datos. Estos drones son una solución real y actual, que irá en aumento debido a la accesibilidad y facilidad de uso.
- 7- La importancia de los **equipos computacionales adecuados:** El aprendizaje continuo de los algoritmos de la Inteligencia Artificial, requieren no solamente tener acceso a grandes bases de datos de calidad, si no en el uso de equipos preparados para afrontar los extensos cálculos de fuerza bruta presentes en los modelos de visión artificial.
Los portátiles dedicados a videojuegos pueden ser una solución barata a pequeña escala gracias a las tarjetas gráficas incorporadas de alta eficiencia y prestaciones, no obstante, no son el equipo especializado en estas tareas.
- 8- **Amplio abanico de herramientas de teledetección y bibliotecas Python dedicadas a la visión artificial:** En este trabajo se ha explorado el uso de Google Earth Engine (GEE) como base de catalogo para diversos conjuntos de datos satelitales y aéreos históricos disponibles públicamente para uso académico y de investigación, con diversas opciones de análisis sin descarga local de ningún archivo. El trabajo conjunto con el software de QGIS, las múltiples librerías de Python; especialmente *geemap* y *rasterio*, donde se permite el acceso y procesado de las imágenes adquiridas en GEE, agilizan todo el pipeline desde el acceso a la imagen a todas las transformaciones necesarias para su procesado, segmentación y creación de la aplicación.

Se concluye finalmente **la viabilidad fehaciente** del uso de estas imágenes para la prevención, evaluación y análisis de riesgos, tales como incendios, fenómenos meteorológicos u otras afectaciones derivadas de la presencia de vegetación en infraestructuras críticas. Asimismo, se presenta la escalabilidad de la aplicación y las vías de mejora continua y optimización, con el objetivo de progresar a un modelo más robusto y una futura automatización y despliegue.

7. Bibliografía

- [1] European Parliament, “Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 ,” 2024. [Online]. Available: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:32024R1689>
- [2] F. Rosenblatt, “The perceptron: A probabilistic model for information storage and organization in the brain.,” *Psychol Rev*, vol. 65, no. 6, pp. 386–408, 1958, doi: 10.1037/h0042519.
- [3] Ministerio de Defensa, “Cuadernos de Estrategia 226,” 2024. [Online]. Available: www.iiiii.es
- [4] F. Aznar Fernández-Montesinos, “¿Qué es Occidente? Occidente ante su identidad: desafíos contemporáneos,” Jan. 2024. [Online]. Available: https://www.iiiii.es/Galerias/fichero/docs_investig/2024/DIEEEINV01_2024_FEDAZ N_Occiden
- [5] R. Q. Quiroga, L. Reddy, G. Kreiman, C. Koch, and I. Fried, “Invariant visual representation by single neurons in the human brain,” *Nature*, vol. 435, no. 7045, pp. 1102–1107, Jun. 2005, doi: 10.1038/nature03687.
- [6] D. H. Hubel and T. N. Wiesel, “Receptive fields of single neurones in the cat’s striate cortex,” *J Physiol*, vol. 148, no. 3, pp. 574–591, Oct. 1959, doi: 10.1113/jphysiol.1959.sp006308.
- [7] M. D. Zeiler and R. Fergus, “Visualizing and Understanding Convolutional Networks,” Nov. 2013.
- [8] K. Simonyan, A. Vedaldi, and A. Zisserman, “Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps,” Dec. 2013.
- [9] A. Fornells, “Business Intelligence in Industrial Engineering,” 2023.
- [10] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” 2012, [Online]. Available: https://papers.nips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf
- [11] EITCA, “¿Cuáles fueron las principales innovaciones introducidas por AlexNet en 2012 que hicieron avanzar significativamente el campo de las redes neuronales convolucionales y el reconocimiento de imágenes?” [Online]. Available: <https://es.eitca.org/artificial-intelligence/eitc-ai-adl-advanced-deep-learning/advanced-computer-vision/convolutional-neural-networks-for-image-recognition/examination-review-convolutional-neural-networks-for-image-recognition/what-were-the-major-innovations-introduced-by-alexnet-in-2012-that->

significantly-advanced-the-field-of-convolutional-neural-networks-and-image-recognition/

- [12] M. Lefkowitz, "Professor's perceptron paved the way for AI – 60 years too soon ," Cornell University. [Online]. Available: <https://news.cornell.edu/stories/2019/09/professors-perceptron-paved-way-ai-60-years-too-soon>
- [13] J. Ma, Y. He, F. Li, L. Han, C. You, and B. Wang, "Segment anything in medical images," *Nat Commun*, vol. 15, no. 1, p. 654, Jan. 2024, doi: 10.1038/s41467-024-44824-z.
- [14] H. Huang *et al.*, "UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation," in *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, IEEE, May 2020, pp. 1055–1059. doi: 10.1109/ICASSP40776.2020.9053405.
- [15] J. Ruan, J. Li, and S. Xiang, "VM-UNet: Vision Mamba UNet for Medical Image Segmentation," Feb. 2024.
- [16] W. Liao, Y. Zhu, X. Wang, C. Pan, Y. Wang, and L. Ma, "LightM-UNet: Mamba Assists in Lightweight UNet for Medical Image Segmentation," Mar. 2024.
- [17] M. Toğaçar, Z. Cömert, and B. Ergen, "Intelligent skin cancer detection applying autoencoder, MobileNetV2 and spiking neural networks," *Chaos Solitons Fractals*, vol. 144, p. 110714, Mar. 2021, doi: 10.1016/j.chaos.2021.110714.
- [18] W. Sae-Lim, W. Wettayaprasit, and P. Aiyarak, "Convolutional Neural Networks Using MobileNet for Skin Lesion Classification," in *2019 16th International Joint Conference on Computer Science and Software Engineering (JCSSE)*, IEEE, Jul. 2019, pp. 242–247. doi: 10.1109/JCSSE.2019.8864155.
- [19] A. Voulodimos, E. Protopapadakis, I. Katsamenis, A. Doulamis, and N. Doulamis, "A Few-Shot U-Net Deep Learning Model for COVID-19 Infected Area Segmentation in CT Images," *Sensors*, vol. 21, no. 6, p. 2215, Mar. 2021, doi: 10.3390/s21062215.
- [20] J. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jun. 2015, pp. 3431–3440. doi: 10.1109/CVPR.2015.7298965.
- [21] geeksforgeeks.org, "What is the difference between a region-based CNN (R-CNN) and a fully convolutional network (FCN)?," <https://www.geeksforgeeks.org/what-is-the-difference-between-a-region-based-cnn-r-cnn-and-a-fully-convolutional-network-fcn/>.

- [22] J. Yan, L. Mu, L. Wang, R. Ranjan, and A. Y. Zomaya, "Temporal Convolutional Networks for the Advance Prediction of ENSO," *Sci Rep*, vol. 10, no. 1, p. 8055, May 2020, doi: 10.1038/s41598-020-65070-5.
- [23] A. Chokshi, "Supporting Fully Convolutional Networks (and U-Net) for Image Segmentation," <https://www.datature.io/blog/supporting-fully-convolutional-networks-and-u-net-for-image-segmentation>.
- [24] A. G. Howard *et al.*, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," Apr. 2017.
- [25] A. G. Howard *et al.*, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," Apr. 2017.
- [26] A. Tragoudaras *et al.*, "Design Space Exploration of a Sparse MobileNetV2 Using High-Level Synthesis and Sparse Matrix Techniques on FPGAs," *Sensors*, vol. 22, no. 12, p. 4318, Jun. 2022, doi: 10.3390/s22124318.
- [27] Y. Hamid, S. Wani, A. B. Soomro, A. A. Alwan, and Y. Gulzar, "Smart Seed Classification System based on MobileNetV2 Architecture," in *2022 2nd International Conference on Computing and Information Technology (ICIT)*, IEEE, Jan. 2022, pp. 217–222. doi: 10.1109/ICIT52419.2022.9711662.
- [28] L. Yong, L. Ma, D. Sun, and L. Du, "Application of MobileNetV2 to waste classification," *PLoS One*, vol. 18, no. 3, p. e0282336, Mar. 2023, doi: 10.1371/journal.pone.0282336.
- [29] M. Akay *et al.*, "Deep Learning Classification of Systemic Sclerosis Skin Using the MobileNetV2 Model," *IEEE Open J Eng Med Biol*, vol. 2, pp. 104–110, 2021, doi: 10.1109/OJEMB.2021.3066097.
- [30] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," Dec. 2015.
- [31] B. Koonce, "ResNet 50," in *Convolutional Neural Networks with Swift for Tensorflow*, Berkeley, CA: Apress, 2021, pp. 63–72. doi: 10.1007/978-1-4842-6168-2_6.
- [32] J. Liang, "Image classification based on RESNET," *J Phys Conf Ser*, vol. 1634, no. 1, p. 012110, Sep. 2020, doi: 10.1088/1742-6596/1634/1/012110.
- [33] Keras, "ResNet and ResNetV2," <https://keras.io/api/applications/resnet/>.
- [34] J. Martínez Calonge, "TFM_Javi."
- [35] ISBI, "The EM Segmentation Challenge," http://brainiac2.mit.edu/isbi_challenge/.
- [36] "Cell Tracking Challenge," <https://celltrackingchallenge.net/>.
- [37] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," May 2015.

- [38] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. L. Yuille, "Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs," Dec. 2014.
- [39] L.-C. Chen, G. Papandreou, F. Schroff, and H. Adam, "Rethinking Atrous Convolution for Semantic Image Segmentation," Jun. 2017.
- [40] Cityscapes Dataset, "Cityscapes Dataset Benchmark Suite," <https://www.cityscapes-dataset.com/benchmarks/>.
- [41] C. Kamann and C. Rother, "Benchmarking the Robustness of Semantic Segmentation Models," in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jun. 2020, pp. 8825–8835. doi: 10.1109/CVPR42600.2020.00885.
- [42] "Semantic Segmentation Benchmarking," <https://paperswithcode.com/task/semantic-segmentation>.
- [43] Si.-H. Tsang, "Review: DeepLabv3+ — Atrous Separable Convolution (Semantic Segmentation)," <https://sh-tsang.medium.com/review-deeplabv3-atrous-separable-convolution-semantic-segmentation-a625f6e83b90>.
- [44] S. Rakshit, "Multiclass semantic segmentation using DeepLabV3+," Jan. 05, 2024, https://keras.io/examples/vision/deeplabv3_plus/.
- [45] C. Atzberger, G. Zeug, P. Defourny, and L. Aragão, "Monitoring of forests through remote sensing – Final report," 2020. [Online]. Available: <https://data.europa.eu/doi/10.2779/175242>
- [46] X. X. Zhu *et al.*, "Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources," *IEEE Geosci Remote Sens Mag*, vol. 5, no. 4, pp. 8–36, Dec. 2017, doi: 10.1109/MGRS.2017.2762307.
- [47] A. A. Adegun, S. Viriri, and J.-R. Tapamo, "Review of deep learning methods for remote sensing satellite images classification: experimental survey and comparative analysis," *J Big Data*, vol. 10, no. 1, p. 93, Jun. 2023, doi: 10.1186/s40537-023-00772-x.
- [48] NASA EARTHDATA, "Remote Sensing," <https://www.earthdata.nasa.gov/learn/earth-observation-data-basics/remote-sensing>.
- [49] GISGeography, "The 50 Most Influential Satellites in Remote Sensing," <https://gisgeography.com/earth-satellite-list>.
- [50] G. Cheng *et al.*, "Object detection in remote sensing imagery using a discriminatively trained mixture model," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 85, pp. 32–43, Nov. 2013, doi: 10.1016/j.isprsjprs.2013.08.001.

- [51] P. Felzenszwalb, D. McAllester, and D. Ramanan, "A discriminatively trained, multiscale, deformable part model," in *2008 IEEE Conference on Computer Vision and Pattern Recognition*, IEEE, Jun. 2008, pp. 1–8. doi: 10.1109/CVPR.2008.4587597.
- [52] A. Boguszewski, D. Batorski, N. Ziemba-Jankowska, T. Dziedzic, and A. Zambrzycka, "LandCover.ai: Dataset for Automatic Mapping of Buildings, Woodlands, Water and Roads from Aerial Imagery," May 2020.
- [53] Y. Wang, X. Gao, Y. Sun, Y. Liu, L. Wang, and M. Liu, "Sh-DeepLabv3+: An Improved Semantic Segmentation Lightweight Network for Corn Straw Cover Form Plot Classification," *Agriculture*, vol. 14, no. 4, p. 628, Apr. 2024, doi: 10.3390/agriculture14040628.
- [54] L. El Hoummaidi, A. Larabi, and K. Alam, "Using unmanned aerial systems and deep learning for agriculture mapping in Dubai," *Heliyon*, vol. 7, no. 10, p. e08154, Oct. 2021, doi: 10.1016/j.heliyon.2021.e08154.
- [55] N. Bengana and J. Heikkila, "Improving Land Cover Segmentation Across Satellites Using Domain Adaptation," *IEEE J Sel Top Appl Earth Obs Remote Sens*, vol. 14, pp. 1399–1410, 2021, doi: 10.1109/JSTARS.2020.3042887.
- [56] É. Clabaut, S. Foucher, Y. Bouroubi, and M. Germain, "Synthetic Data for Sentinel-2 Semantic Segmentation," *Remote Sens (Basel)*, vol. 16, no. 5, p. 818, Feb. 2024, doi: 10.3390/rs16050818.
- [57] R. Wenger, A. Puissant, J. Weber, L. Idoumghar, and G. Forestier, "Multimodal and Multitemporal Land Use/Land Cover Semantic Segmentation on Sentinel-1 and Sentinel-2 Imagery: An Application on a MultiSenGE Dataset," *Remote Sens (Basel)*, vol. 15, no. 1, p. 151, Dec. 2022, doi: 10.3390/rs15010151.
- [58] C. E. Akumu, E. O. Amadi, and S. Dennis, "Application of Drone and WorldView-4 Satellite Data in Mapping and Monitoring Grazing Land Cover and Pasture Quality: Pre- and Post-Flooding," *Land (Basel)*, vol. 10, no. 3, p. 321, Mar. 2021, doi: 10.3390/land10030321.
- [59] D. Rashkovetsky, F. Mauracher, M. Langer, and M. Schmitt, "Wildfire Detection From Multisensor Satellite Imagery Using Deep Semantic Segmentation," *IEEE J Sel Top Appl Earth Obs Remote Sens*, vol. 14, pp. 7001–7016, 2021, doi: 10.1109/JSTARS.2021.3093625.
- [60] Y. Chen, H. Jiang, C. Li, X. Jia, and P. Ghamisi, "Deep Feature Extraction and Classification of Hyperspectral Images Based on Convolutional Neural Networks," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 54, no. 10, pp. 6232–6251, Oct. 2016, doi: 10.1109/TGRS.2016.2584107.

- [61] P. Liu and G. Zhang, "A Case Study on the Integration of Remote Sensing for Predicting Complicated Forest Fire Spread," *Remote Sens (Basel)*, vol. 16, no. 21, p. 3969, Oct. 2024, doi: 10.3390/rs16213969.
- [62] F. Sivrikaya, A. Günlü, Ö. Küçük, and O. Ürker, "Forest fire risk mapping with Landsat 8 OLI images: Evaluation of the potential use of vegetation indices," *Ecol Inform*, vol. 79, p. 102461, Mar. 2024, doi: 10.1016/j.ecoinf.2024.102461.
- [63] M. Sheykhoumoussa, M. Mahdianpari, H. Ghanbari, F. Mohammadimanesh, P. Ghamisi, and S. Homayouni, "Support Vector Machine Versus Random Forest for Remote Sensing Image Classification: A Meta-Analysis and Systematic Review," *IEEE J Sel Top Appl Earth Obs Remote Sens*, vol. 13, pp. 6308–6325, 2020, doi: 10.1109/JSTARS.2020.3026724.
- [64] B. C. Pijanowski, D. G. Brown, B. A. Shellito, and G. A. Manik, "Using neural networks and GIS to forecast land use changes: a Land Transformation Model," *Comput Environ Urban Syst*, vol. 26, no. 6, pp. 553–575, Nov. 2002, doi: 10.1016/S0198-9715(01)00015-1.
- [65] A. Farbo, F. Sarvia, S. De Petris, V. Basile, and E. Borgogno-Mondino, "Forecasting corn NDVI through AI-based approaches using sentinel 2 image time series," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 211, pp. 244–261, May 2024, doi: 10.1016/j.isprsjprs.2024.04.011.
- [66] Peter. Bruce, Andrew. Bruce, and Peter. Gedeck, *Practical Statistics for Data Scientists, 2nd Edition*. O'Reilly Media, Inc., 2020.
- [67] Google, "Tensorflow 3," <https://www.tensorflow.org/?hl=es-419>.
- [68] "Keras library for Python," <https://keras.io/>.
- [69] S. Gillies, "Rasterio Documentation Release 1.5.0.dev," 2025.
- [70] Q. Wu, "Geemap," <https://geemap.org/>.
- [71] R. Julve and D. Jiménez, "Antes y después de la DANA: Las imágenes de satélite muestran los estragos del temporal en Valencia," Nov. 01, 2024.
- [72] MAXAR, "Satellite imagery for select sudden onset major crisis events."
- [73] T. Krantz and A. Jonker, "What is ground truth? ."
- [74] R. P. Gupta, *Remote Sensing Geology*. Springer, 2013.
- [75] M. Arzt *et al.*, "LABKIT: Labeling and Segmentation Toolkit for Big Image Data," *Front Comput Sci*, vol. 4, Feb. 2022, doi: 10.3389/fcomp.2022.777728.

- [76] T. Pietzsch, S. Saalfeld, S. Preibisch, and P. Tomancak, "BigDataViewer: visualization and processing for large image data sets," *Nat Methods*, vol. 12, no. 6, pp. 481–483, Jun. 2015, doi: 10.1038/nmeth.3392.
- [77] J. Schindelin *et al.*, "Fiji: an open-source platform for biological-image analysis," *Nat Methods*, vol. 9, no. 7, pp. 676–682, Jul. 2012, doi: 10.1038/nmeth.2019.
- [78] C. A. Schneider, W. S. Rasband, and K. W. Eliceiri, "NIH Image to ImageJ: 25 years of image analysis," *Nat Methods*, vol. 9, no. 7, pp. 671–675, Jul. 2012, doi: 10.1038/nmeth.2089.
- [79] C. Tischer, A. Ravindran, S. Reither, R. Pepperkok, and N. Norlin, "BigDataProcessor2: A free and open-source Fiji plugin for inspection and processing of TB sized image data," Sep. 23, 2020. doi: 10.1101/2020.09.23.244095.
- [80] L. Breiman, "Random Forest," *Mach Learn*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [81] Supek, "Fast Random Forest," 2015, <https://code.google.com/archive/p/fast-random-forest/>.
- [82] Q. Zhang, Y. Zhu, M. Yang, G. Jin, Y. Zhu, and Q. Chen, "Cross-to-merge training with class balance strategy for learning with noisy labels," *Expert Syst Appl*, vol. 249, p. 123846, Sep. 2024, doi: 10.1016/j.eswa.2024.123846.
- [83] C. Tian, L. Fei, W. Zheng, Y. Xu, W. Zuo, and C.-W. Lin, "Deep learning on image denoising: An overview," *Neural Networks*, vol. 131, pp. 251–275, Nov. 2020, doi: 10.1016/j.neunet.2020.07.025.
- [84] X. Zhang, L. Han, L. Han, and L. Zhu, "How Well Do Deep Learning-Based Methods for Land Cover Classification and Object Detection Perform on High Resolution Remote Sensing Imagery?," *Remote Sens (Basel)*, vol. 12, no. 3, p. 417, Jan. 2020, doi: 10.3390/rs12030417.
- [85] A. Tzepkenlis, K. Marthoglou, and N. Grammalidis, "Efficient Deep Semantic Segmentation for Land Cover Classification Using Sentinel Imagery," *Remote Sens (Basel)*, vol. 15, no. 8, p. 2027, Apr. 2023, doi: 10.3390/rs15082027.
- [86] P. Maahi, "The Complete Guide to Image Preprocessing Techniques in Python."
- [87] S. Chatterjee, D. Dey, and S. Munshi, "Preprocessing and segmentation of skin lesion images," in *Recent Trends in Computer-Aided Diagnostic Systems for Skin Diseases*, Elsevier, 2022, pp. 25–52. doi: 10.1016/B978-0-323-91211-2.00002-0.
- [88] C. Shorten and T. M. Khoshgoftaar, "A survey on Image Data Augmentation for Deep Learning," *J Big Data*, vol. 6, no. 1, p. 60, Dec. 2019, doi: 10.1186/s40537-019-0197-0.

- [89] S. Yang, W. Xiao, M. Zhang, S. Guo, J. Zhao, and F. Shen, "Image Data Augmentation for Deep Learning: A Survey," Apr. 2022.
- [90] P. Chlap, H. Min, N. Vandenberg, J. Dowling, L. Holloway, and A. Haworth, "A review of medical image data augmentation techniques for deep learning applications," *J Med Imaging Radiat Oncol*, vol. 65, no. 5, pp. 545–563, Aug. 2021, doi: 10.1111/1754-9485.13261.
- [91] R. Gondur, "Choosing the Right Optimizer: A Brief Look at Adam," Apr. 26, 2024.
- [92] Geeksforgeeks.org, "What is Adam Optimizer?," 2025.
- [93] A. Mortazi, V. Cicek, E. Keles, and U. Bagci, "Selecting the Best Optimizers for Deep Learning based Medical Image Segmentation," Feb. 2023.
- [94] L. N. Smith, "A disciplined approach to neural network hyper-parameters: Part 1 -- learning rate, batch size, momentum, and weight decay," Mar. 2018.
- [95] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation," Feb. 2018.
- [96] I. Demir *et al.*, "DeepGlobe 2018: A Challenge to Parse the Earth through Satellite Images," May 2018, doi: 10.1109/CVPRW.2018.00031.
- [97] N. Gährlert, N. Jourdan, M. Cordts, U. Franke, and J. Denzler, "Cityscapes 3D: Dataset and Benchmark for 9 DoF Vehicle Detection," Jun. 2020.
- [98] B. Zhou, H. Zhao, X. Puig, S. Fidler, A. Barriuso, and A. Torralba, "Scene Parsing through ADE20K Dataset," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jul. 2017, pp. 5122–5130. doi: 10.1109/CVPR.2017.544.
- [99] R. Ranftl, A. Bochkovskiy, and V. Koltun, "Vision Transformers for Dense Prediction," Mar. 2021.
- [100] I. P. Senanayake, I.-Y. Yeo, and G. A. Kuczera, "Three Decades of Inundation Dynamics in an Australian Dryland Wetland: An Eco-Hydrological Perspective," *Remote Sens (Basel)*, vol. 16, no. 17, p. 3310, Sep. 2024, doi: 10.3390/rs16173310.
- [101] N. Jones, "How to stop data centres from gobbling up the world's electricity," *Nature*, vol. 561, no. 7722, pp. 163–166, Sep. 2018, doi: 10.1038/d41586-018-06610-y.
- [102] Enel X S.r.l, "¿Cómo de eficientes energéticamente son los centros de datos?," <https://corporate.enelx.com/es/stories/2021/12/data-center-industry-sustainability>.
- [103] Google, "Innovating sustainable ideas. Growing renewable solutions.," <https://datacenters.google/operating-sustainably/>.
- [104] P. Ball, "Computer engineering: Feeling the heat," *Nature*, vol. 492, no. 7428, pp. 174–176, Dec. 2012, doi: 10.1038/492174a.

- [105] Generalitat de Catalunya, “ Factor de emisión de la energía eléctrica: el mix eléctrico,” https://canviclimatic.gencat.cat/es/actua/factors_demissio_associats_a_lenergia/index.html.
- [106] NVIDIA, “NVIDIA potencia la IA del mundo. Y la tuya. ,” <https://www.nvidia.com/es-es/ai-on-rtx/>.
- [107] Endesa, “¿Cuál es el consumo de un ordenador de gaming?,” <https://www.endesa.com/es/blog/blog-de-endesa/luz/consumo-ordenador-gaming>.